

Методология формирования доменных коллекций с разметкой полезности и надежности документов

Григорьев Д. А., Чернышев Д. И.

09.09.2026

Аннотация

В работе рассматривается методология формирования доменных коллекций для больших языковых моделей.

1. Введение

Заполнится после.

2. Литературный обзор

Качество данных для предварительного обучения больших языковых моделей является критическим фактором, определяющим их итоговую производительность. За последние годы был предложен ряд крупных открытых корпусов, различающихся по источникам, объёму и методам очистки. В данном обзоре мы рассматриваем эволюцию подходов к созданию тренировочных датасетов, чтобы обосновать необходимость разработки инструментов для детальной разметки полезности и надёжности документов относительно предметных доменов.

Ранние работы, такие как **The Pile** [1] предложили подход, основанный на агрегации множества разнородных источников. Он представляет собой англоязычный корпус объёмом около 825 ГБ, объединяющий научные статьи, книги, программный код, судебные документы и веб-страницы. Разделение данных в нём определяется источником происхождения, а не содержательными характеристиками отдельных документов. **OSCAR** [2] сделал шаг в сторону автоматической фильтрации веб-контента из Common Crawl и ориентирован на построение крупных многоязычных корпусов с автоматическим определением языка и базовой фильтрацией веб-текстов. В более поздних версиях обработка была перенесена с отдельных строк на целые документы, а корпус дополнен метаданными о качестве и потенциально нежелательном содержании.

RefinedWeb [3] демонстрирует, что тщательно очищенные веб-данные могут быть конкурентоспособны по отношению к корпусам, составленным из множества специализированных источников. Его обработка включает извлечение основного текста, языковую фильтрацию и удаление низкокачественных документов. **CulturaX** [4] развивает подходы к масштабируемой очистке многоязычных веб-корпусов. Набор данных построен на основе mC4 и OSCAR и содержит более 6 трлн токенов для 167 языков. Его обработка включает языковую идентификацию, фильтрацию URL, очистку на основе текстовых метрик и дедупликацию, а пороги фильтрации определяются отдельно для каждого языка.

FineWeb [5] продолжает развитие подходов к созданию крупных корпусов на основе Common Crawl. Набор данных содержит около 15 триллионов токенов, полученных из Common Crawl. Авторы подробно исследуют влияние отдельных этапов обработки, включая дедупликацию, фильтрацию низкокачественных документов и удаление нежелательного содержимого. На основе FineWeb также была сформирована коллекция **FineWeb-Edu**, содержащая тексты с высокой образовательной ценностью. Для её построения использовалась модельная оценка качества документов, что позволило выделить около 1,3 трлн токенов образовательного содержания.

FineWeb2 [6] адаптирует предложенный в FineWeb процесс обработки для многоязычных веб-данных. Полученный корпус занимает около 20 ТБ, содержит примерно 5 млрд документов и охватывает более 1000 языков. FineWeb2 представляет собой один из наиболее масштабных открытых многоязычных корпусов, однако его разметка также в первую очередь ориентирована на общее качество документов, а не на их принадлежность конкретным предметным областям.

Рассмотренные работы демонстрируют постепенный переход от объединения заранее выбранных источников к масштабируемой автоматической очистке и модельной оценке качества веб-документов. При этом содержательная принадлежность документа к предметной области, его образовательная ценность, надёжность и потенциальные риски обычно не представлены в виде единого набора признаков. Это ограничивает возможности формирования специализированных обучающих коллекций с заданными требованиями к тематике и качеству содержимого.

3. Методология формирования доменных коллекций

3.1. Общая схема обработки

Предлагаемый подход представляет собой последовательный пайплайн разметки и отбора документов из крупного веб-корпуса. На первом этапе документы группируются по доменам, после чего из корпуса формируется ограниченная выборка для первичной разметки. Каждый текст из этой выборки передается крупной языковой модели, которая присваивает ему набор тематических тегов в свободной форме.

Поскольку исходный набор тегов содержит большое количество близких и дублирующих формулировок, полученные теги дополнительно группируются в семантически однородные кластеры. Для каждого кластера выбирается репрезентативный тег, благодаря чему формируется фиксированное множество меток. На основе данной разметки обучается модель-теггер, которая затем применяется ко всему исходному корпусу.

Полученные предсказания используются для формирования коллекций, относящихся к заданным предметным областям. Кроме тематических тегов, каждому документу могут быть присвоены дополнительные характеристики, в том числе оценка образовательной ценности, токсичности и другие признаки, полезные при отборе данных для обучения языковых моделей.

3.2. Методология обучения теггера

Исходная разметка создается крупной языковой моделью, которая присваивает каждому документу фиксированное число свободных тегов. Поскольку такая разметка содержит большое количество синонимичных, близких и частично пересекающихся тегов, перед обучением теггера производится кластеризация схожих тегов.

Теги группируются в кластеры с помощью эвристического подхода, основанного на агломеративной кластеризации. Для каждого кластера выбирается репрезентативный тег, который используется как имя кластера. После этого исходная разметка заменяется на разметку по кластеризованному пространству тегов.

Задача теггера формулируется как многоклассовая мульти-лейбл разметка. Для каждого документа модель возвращает вектор вероятностей:

$$\mathbf{p}(x) = (p_1, p_2, \dots, p_K), \quad (1)$$

где x --- текст документа, K --- общее число тегов, а p_i --- оценка принадлежности документа к i -му тегу. Итоговый набор тегов определяется с помощью порога τ :

$$y_i = \mathbb{I}(p_i > \tau). \quad (2)$$

Порог выбирается эмпирически по качеству на обучающей выборке с учетом точности, полноты и F1-меры.

3.3. Методология определения домена документа

Для формирования коллекции под целевой домен сначала определяется множество тегов, связанных с данным доменом. Такое множество может быть построено экспертно или с использованием крупной языковой модели. Документ включается в доменную коллекцию, если его набор тегов содержит не менее заданного числа доменных тегов. Для документов, не удовлетворяющих этому условию, применяется дополнительная проверка на основе семантического сходства. Набор тегов документа преобразуется в текстовое описание и сравнивается с текстовым описанием целевого домена в эмбединговом пространстве. Если сходство превышает заданный порог, документ также включается в коллекцию. Таким образом, отбор документов сочетает два критерия: жесткое правило по числу доменных тегов и мягкий семантический критерий.

3.4. Методология оценки токсичности

TODO

3.5. Методология оценки образовательной ценности

Оценка образовательной ценности строится по той же схеме. Крупная языковая модель используется для присвоения документам оценки по дискретной шкале. Затем на полученной разметке обучается компактная модель, которая применяется ко всему корпусу.

Каждому документу сопоставляется значение из множества:

$$e(x) \in \{0, 1, 2, 3, 4, 5\}, \quad (3)$$

где большие значения соответствуют большей образовательной ценности документа.

3.6. Дополнительные фичи документов

К дополнительным признакам могут относиться длина документа, сайт-источник, домен, набор тегов, признаки коммерческого или рекламного характера, оценка качества орфографии и прочее.

4. Описание доменной коллекции для русского языка

4.1. Описание данных и параметры классификаторов

В качестве исходного корпуса использовался раздел `rusCyrL` датасета `FineWeb2`. Документы группировались по доменам сайтов. Для каждого домена сохранялось не более 10 различных текстов, что позволило получить корпус объемом около 35 млн документов. Для первичной разметки использовалась крупная языковая модель `Qwen3-235B`. Модель размечала каждый текст отдельно и присваивала ему ровно 5 тегов в свободной форме. Всего было размечено около 10 тыс. сайтов. В результате было получено около 100 тыс. уникальных исходных тегов. Далее теги были сгруппированы с помощью эвристической процедуры кластеризации. После объединения близких тегов было получено 788 кластеров. Для каждого кластера модель `Qwen` выбирала репрезентативное название на основе 10 наиболее частотных тегов внутри кластера. На полученной разметке был обучен многометочный теггер на основе `RuModernBERT` от `VK`. Модель возвращала вектор из 788 значений от 0 до 1. Тег присваивался документу, если соответствующее значение превышало выбранный порог. Порог подбирался на обучающей или отложенной выборке по метрикам `precision`, `recall` и `F1`.

Таблица 1: Пример подбора порога для теггера при $k = 3$

Порог	Точность	Полнота	F1
0.00	0.7584	0.5576	0.6427
0.10	0.7604	0.5573	0.6432
0.20	0.7725	0.5544	0.6455
0.25	0.7815	0.5509	0.6463
0.30	0.7920	0.5453	0.6459
0.40	0.8175	0.5279	0.6416
0.50	0.8442	0.4996	0.6277
0.60	0.8757	0.4600	0.6032
0.70	0.9046	0.4070	0.5615

Для дальнейших экспериментов использовался порог 0.25, обеспечивший наибольшее значение `F1` в приведенной конфигурации.

4.2. Анализ качества `FineWeb2-rus` по результатам разметки

Первичный анализ распределения тегов показывает, что в корпусе присутствуют как содержательные тематические категории, так и значительная доля коммерческих, развлекательных и потенциально нежелательных документов. Среди наиболее частотных тегов встречаются туризм, онлайн-магазины, образование, строительство, дизайн интерьера, здоровье, производство, азартные игры, игры, акции и скидки, отели, медицина, финансы и прочее.

4.3. Распределение документов по набору доменов

В качестве первого примера доменной коллекции была собрана коллекция по юриспруденции. Для этого множество из 788 тегов было проанализировано крупной языковой

моделью, которая определила теги, относящиеся к юридическому домену. Предварительно к юридическим было отнесено около 40 тегов.

Документ включался в юридическую коллекцию, если выполнялось хотя бы одно из двух условий:

1. документ имел не менее трех тегов из юридического множества;
2. документ содержит от 1 до 2 юридических тегов и семантическое сходство между текстовым описанием тегов документа и запросом *"Тексты про юриспруденцию, законы, суды и т.д."* превышало 0.39.

Для вычисления эмбедингов использовалась модель `sergeyzh/BERTA`. Порог 0.39 был выбран эмпирически на основе предварительного просмотра результатов на нескольких текстах. В результате было получено около 3 млн документов юридической тематики.

4.4. Распределение фич по доменам и тегам

Таблица 2: Распределение числа тегов на документ после применения теггера

Число тегов	Число документов	Доля
0	36689	0.1%
1	846632	2.4%
2	3869365	10.9%
3	8008849	22.5%
4	9365606	26.3%
5	7223097	20.3%
6	3962951	11.1%
7	1609156	4.5%
8	516997	1.5%
9	137853	0.4%
10	32381	0.1%

4.5. Сравнение распределений образовательной ценности для топовых моделей

Модель Qwen3-235B присваивала текстам оценку образовательной ценности по шкале от 0 до 5.

5. Ограничения

На текущем этапе качество некоторых этапов пайплайна оценивалось преимущественно автоматически или путем предварительного просмотра результатов. В частности, требуется дополнительная ручная валидация качества доменного отбора, качества теггера и оценок образовательной ценности. Также необходимо более строго обосновать выбор порогов для семантического сходства и для классификаторов.

6. Заключение

В статье предложен пайплайн формирования доменно-ориентированных обучающих коллекций, основанный на разметке крупной языковой моделью, кластеризации свободных тегов, обучении компактных классификаторов и последующем масштабировании разметки на большой веб-корпус. На примере русскоязычного корпуса FineWeb2 показано, что такой подход позволяет получать доменные коллекции с дополнительными признаками полезности и надежности документов.

Список литературы

- [1] L. Gao et al. *The Pile: An 800GB Dataset of Diverse Text for Language Modeling*. 2020. <https://arxiv.org/abs/2101.00027>
- [2] J. Abadji et al. *Towards a Cleaner Document-Oriented Multilingual Crawled Corpus*. 2022. <https://aclanthology.org/2022.lrec-1.463/>
- [3] G. Penedo et al. *The RefinedWeb Dataset for Falcon LLM: Outperforming Curated Corpora with Web Data, and Web Data Only*. 2023. <https://arxiv.org/abs/2306.01116>
- [4] T. Nguyen et al. *CulturaX: A Cleaned, Enormous, and Multilingual Dataset for Large Language Models in 167 Languages*. 2024. <https://aclanthology.org/2024.lrec-main.377/>
- [5] Penedo, Guilherme, et al. "The fineweb datasets: Decanting the web for the finest text data at scale." *Advances in Neural Information Processing Systems* 37 (2024): 30811-30849.
- [6] Penedo, Guilherme, et al. "FineWeb2: One Pipeline to Scale Them All--Adapting Pre-Training Data Processing to Every Language." (2025).