

Методология формирования доменных коллекций с разметкой полезности и надежности документов

Григорьев Д. А., Чернышев Д. И.

09.09.2026

Аннотация

В работе рассматривается методология формирования доменных коллекций для больших языковых моделей.

1. Введение

Качество данных предварительного обучения является одним из ключевых факторов, определяющих эффективность больших языковых моделей. В последние годы появилось множество крупных открытых корпусов, однако большинство из них ориентированы на английский язык или предлагают лишь общую фильтрацию качества, без привязки к предметным областям. Для русского языка ситуация еще более острая: доступные коллекции часто ограничены по объему или не имеют содержательной разметки.

В данной работе мы предлагаем методологию формирования доменных коллекций с дополнительными признаками полезности и надежности документов. Наш подход основан на двухэтапной схеме: крупная языковая модель размечает ограниченную выборку текстов свободными тегами и оценками, затем эти данные используются для обучения компактных классификаторов, которые масштабируются на весь набор данных.

2. Литературный обзор

Качество данных для предварительного обучения больших языковых моделей является критическим фактором, определяющим их итоговую производительность. За последние годы был предложен ряд крупных открытых корпусов, различающихся по источникам, объему и методам очистки. В данном обзоре мы рассматриваем эволюцию подходов к созданию тренировочных датасетов, чтобы обосновать необходимость разработки инструментов для детальной разметки полезности и надежности документов относительно предметных доменов.

Ранние работы, такие как **The Pile** [1] предложили подход, основанный на агрегации множества разнородных источников. Он представляет собой англоязычный корпус объемом около 825 ГБ, объединяющий научные статьи, книги, программный код, судебные документы и веб-страницы. Разделение данных в нем определяется источником происхождения, а не содержательными характеристиками отдельных документов. **OSCAR** [2] сделал шаг в сторону автоматической фильтрации веб-контента из Common Crawl и ориентирован на построение крупных многоязычных корпусов с автоматическим определением языка и базовой фильтрацией веб-текстов. В более поздних версиях обработка была

перенесена с отдельных строк на целые документы, а корпус дополнен метаданными о качестве и потенциально нежелательном содержании.

RefinedWeb [3] демонстрирует, что тщательно очищенные веб-данные могут быть конкурентоспособны по отношению к корпусам, составленным из множества специализированных источников. Его обработка включает извлечение основного текста, языковую фильтрацию и удаление низкокачественных документов. **CulturaX** [4] развивает подходы к масштабируемой очистке многоязычных веб-корпусов. Набор данных построен на основе mC4 и OSCAR и содержит более 6 трлн токенов для 167 языков. Его обработка включает языковую идентификацию, фильтрацию URL, очистку на основе текстовых метрик и дедупликацию, а пороги фильтрации определяются отдельно для каждого языка.

FineWeb [5] продолжает развитие подходов к созданию крупных корпусов на основе Common Crawl. Набор данных содержит около 15 триллионов токенов, полученных из Common Crawl. Авторы подробно исследуют влияние отдельных этапов обработки, включая дедупликацию, фильтрацию низкокачественных документов и удаление нежелательного содержимого. На основе FineWeb также была сформирована коллекция **FineWeb-Edu**, содержащая тексты с высокой образовательной ценностью. Для ее построения использовалась модельная оценка качества документов, что позволило выделить около 1,3 трлн токенов образовательного содержания.

FineWeb2 [6] адаптирует предложенный в FineWeb процесс обработки для многоязычных веб-данных. Полученный корпус занимает около 20 ТБ, содержит примерно 5 млрд документов и охватывает более 1000 языков. FineWeb2 представляет собой один из наиболее масштабных открытых многоязычных корпусов, однако его разметка также в первую очередь ориентирована на общее качество документов, а не на их принадлежность конкретным предметным областям.

Рассмотренные работы демонстрируют постепенный переход от объединения заранее выбранных источников к масштабируемой автоматической очистке и модельной оценке качества веб-документов. При этом содержательная принадлежность документа к предметной области, его образовательная ценность, надежность и потенциальные риски обычно не представлены в виде единого набора признаков. Это ограничивает возможности формирования специализированных обучающих коллекций с заданными требованиями к тематике и качеству содержимого.

3. Методология формирования доменных коллекций

3.1. Общая схема обработки

Предлагаемый подход представляет собой последовательный пайплайн разметки и отбора документов из крупного веб-корпуса. На первом этапе документы группируются по доменам, после чего из корпуса формируется ограниченная выборка для первичной разметки. Каждый текст из этой выборки передается крупной языковой модели, которая присваивает ему набор тематических тегов в свободной форме.

Поскольку исходный набор тегов содержит большое количество близких и дублирующих формулировок, полученные теги дополнительно группируются в семантически однородные кластеры. Для каждого кластера выбирается репрезентативный тег, благодаря чему формируется фиксированное множество меток. На основе данной разметки обучается модель-теггер, которая затем применяется ко всему исходному корпусу.

Полученные предсказания используются для формирования коллекций, относящихся к заданным предметным областям. Кроме тематических тегов, каждому документу могут

быть присвоены дополнительные характеристики, в том числе оценка образовательной ценности, токсичности и другие признаки, полезные при отборе данных для обучения языковых моделей.

3.2. Обучение теггера

Тематическая разметка веб-корпуса может быть получена непосредственно с помощью крупной языковой модели. Однако применение такой модели ко всему корпусу требует значительных вычислительных затрат. Поэтому в работе используется двухэтапная схема типа *LLM--BERT*: крупная языковая модель формирует исходную разметку для ограниченной выборки документов, после чего на полученных данных обучается компактный тематический теггер, предназначенный для обработки полного корпуса. Для получения более контролируемых результатов производилось несколько запусков LLM на каждый сайт и выбирался наиболее частый ответ.

Пусть

$$\mathcal{D} = x_1, x_2, \dots, x_N \quad (1)$$

- выборка документов, используемая для построения обучающей разметки. Для каждого документа x_n языковая модель M формирует фиксированное число кратких тематических тегов:

$$M(x_n; q) = t_{n1}, t_{n2}, \dots, t_{nm} = T(x_n), \quad (2)$$

где q - инструкция для модели, а t_{nj} - свободный текстовый тег, описывающий одну из тем документа. Использование свободных тегов позволяет не задавать тематическую таксономию заранее и учитывать содержание конкретного корпуса. Вместе с тем такая разметка не является полностью согласованной: одна и та же тема может быть обозначена синонимичными формулировками, различными тегами.

Перед построением фиксированного пространства классов выполняется нормализация тегов. Нормализация включает приведение к единому регистру, удаление лишних пробелов и специальных символов, унификацию разделителей и исключение дубликатов внутри одного документа. После нормализации формируется множество уникальных свободных тегов $\mathcal{U}$.

Размер множества $\mathcal{U}$ может быть существенно больше числа тематических классов, необходимого для обучения классификатора. Например, теги, обозначающие одну предметную область, могут отличаться порядком слов, используемой терминологией или уровнем обобщения. Для преобразования открытого пространства тегов в конечную таксономию применяется их семантическая кластеризация.

Каждому нормализованному тегу $u \in \mathcal{U}$ сопоставляется векторное представление, полученное с помощью модели текстовых эмбедингов E :

$$\mathbf{e}_u = E(u) \quad (3)$$

Семантическая близость двух тегов определяется косинусным сходством:

$$s(u_i, u_j) = \cos(\mathbf{e}_{u_i}, \mathbf{e}_{u_j}) = \mathbf{e}_{u_i}^\top \mathbf{e}_{u_j}. \quad (4)$$

Соответствующее расстояние задается как

$$d(u_i, u_j) = 1 - s(u_i, u_j). \quad (5)$$

Прямое применение агломеративной кластеризации ко всему множеству уникальных тегов требует хранения попарных расстояний и плохо масштабируется при увеличении размера словаря. Поэтому используется гибридная процедура кластеризации. На первом этапе из множества тегов выбирается подмножество $\mathcal{U}_0 \subset \mathcal{U}$, для которого выполняется агломеративная кластеризация по семантическому расстоянию. В результате формируется начальное множество кластеров

$$\mathcal{C}^{(0)} = C_1, C_2, \dots, C_K. \quad (6)$$

Для каждого кластера вычисляется нормированный центр μ_k .

Оставшиеся теги присоединяются к кластеру с наиболее близким центром:

$$c(u) = \arg \max_{k \in 1, \dots, K} \mathbf{e}_u^T \mu_k. \quad (7)$$

Такой подход позволяет применять более точную агломеративную кластеризацию к ограниченной части тегов, а оставшуюся разметку обрабатывать линейно относительно числа тегов и кластеров. Чрезмерно крупные кластеры дополнительно разделяются, поскольку они могут объединять несколько смежных, но различных тематик. Ограничение размера кластера предотвращает формирование слишком общих категорий, мало полезных для последующего отбора доменных документов.

Каждому кластеру C_k присваивается название v_k . Оно формируется на основании множества входящих в кластер тегов и должно кратко отражать их общую семантику:

$$v_k = M(C_k), \quad (8)$$

где M - языковая модель, используемая для именования кластеров. В результате формируется конечный словарь тематических классов

$$\mathcal{V} = v_1, v_2, \dots, v_K. \quad (9)$$

Каждому исходному свободному тегу сопоставляется новый тег соответствующего кластера:

$$\varphi(u) = v_{c(u)}. \quad (10)$$

После этого исходная разметка документов преобразуется в кластеризованное пространство:

$$T^*(x_n) = \{\varphi(u) \mid u \in T(x_n)\}. \quad (11)$$

Таким образом, синонимичные и близкие свободные теги заменяются общим тематическим классом. При этом один документ может одновременно относиться к нескольким темам. Поэтому задача обучения теггера формулируется как задача классификации по многим меткам.

Для документа x_n строится бинарный вектор целевых меток

$$\mathbf{y}_n = (y_{n1}, y_{n2}, \dots, y_{nK}) \in \{0, 1\}^K, \quad (12)$$

где

$$y_{ni} = \mathbb{I}[v_i \in T^*(x_n)]. \quad (13)$$

В качестве основы теггера используется предварительно обученный кодировщик текста. Для документа вычисляется контекстное представление и полученное значение пропускается через линейный слой классификатора.

$$\mathbf{z}_n = F(x_n), \quad (14)$$

где F - модель классификатор, а $\mathbf{z}_n$ - вектор логитов.

В отличие от многоклассовой классификации, где выходы модели нормируются совместно с помощью функции softmax, в задаче классификации по многим меткам вероятность каждого тега оценивается независимо:

$$p_{ni} = \frac{1}{1 + \exp(-z_{ni})}. \quad (15)$$

Итоговый выход модели имеет вид

$$\mathbf{p}(x_n) = (p_{n1}, p_{n2}, \dots, p_{nK}), \quad (16)$$

где p_{ni} интерпретируется как оценка принадлежности документа x_n тематическому классу v_i .

После обучения вероятностные оценки преобразуются в итоговый набор тегов с помощью порога τ :

$$\hat{y}_i(x) = \mathbb{I}[p_i(x) \geq \tau], \quad (17)$$

$$\hat{T}(x; \tau) = \{v_i \in \mathcal{V} \mid p_i(x) \geq \tau\}. \quad (18)$$

Снижение порога увеличивает число присваиваемых тегов и полноту разметки, но одновременно повышает число ложноположительных предсказаний. Повышение порога, напротив, увеличивает точность, но приводит к потере менее выраженных тематик. Поэтому значение τ подбирается на отложенной выборке, не использовавшейся для оптимизации параметров модели.

Для оценки качества используются точность, полнота и F_1 -мера. Оптимальный порог может быть определен как

$$\tau^* = \arg \max_{\tau \in \mathcal{T}} F_{1,\text{micro}}(\tau), \quad (19)$$

где $\mathcal{T}$ - множество проверяемых пороговых значений.

Таким образом, предложенная методология преобразует открытую тематическую разметку языковой модели в фиксированное многометочное пространство. Крупная языковая модель применяется только на этапе построения исходной выборки и именования тематических кластеров, тогда как основная часть корпуса обрабатывается компактным трансформерным теггером. Это снижает вычислительную стоимость разметки и позволяет масштабировать ее на коллекции, содержащие большое число документов.

3.3. Определения домена документа

Для определения принадлежности документа предметной области используются результаты тематического теггера. Каждому документу x сопоставляется множество тегов, вероятность которых превышает установленный порог.

Для каждой предметной области Ω заранее задается множество связанных с ней тегов T_Ω . Требуется собрать множество документов X_Ω - набор документов, релевантных этой области. Первым критерием принадлежности документа домену является число найденных доменных тегов:

$$n_\Omega(d) = |T(x) \cap T_\Omega|. \quad (20)$$

Однако использование только количества тегов может приводить к пропуску потенциально релевантных документов. Поэтому дополнительно вычисляется семантическая близость между набором тегов документа и текстовым описанием предметной области для документов, у которых есть хотя бы один релевантный тег, но их недостаточно, чтобы включить в коллекцию. Для этого они преобразуются в векторные представления с помощью модели эмбедингов, после чего рассчитывается косинусное сходство. Документ включается в доменную коллекцию, если для него найдено достаточное число доменных тегов либо если меньшее число тегов сочетается с высокой семантической близостью:

$$x \in X_\Omega \iff n_\Omega(x) \geq m \vee (n_\Omega(x) \geq 1 \wedge s_\Omega(x) \geq \tau_{\text{sem}}). \quad (21)$$

где q_Ω - текстовое описание предметной области, $s_\Omega(x)$ - косинусное сходство между текстовым описанием предметной области и набором тегов.

Первое условие соответствует жесткому отбору по тематическим тегам. Второе позволяет включить документы с меньшим числом явных доменных признаков, если совокупность их тегов семантически близка к заданной области.

Параметры m и τ_{sem} подбираются на ручную размеченную выборку.

3.4. Оценка токсичности

Помимо тематической принадлежности при формировании специализированных обучающих коллекций необходимо учитывать наличие в документах потенциально вредоносного содержания. В рамках настоящей работы под токсичностью понимается характеристика, отражающая риск присутствия в тексте агрессивной риторики, оскорблений, языка ненависти, описания или пропаганды опасных действий, а также другого содержания, нежелательного для включения в обучающую коллекцию без дополнительной проверки.

Для получения обучающей выборки используется модель-учитель, которая присваивает каждому документу оценку риска вредоносного содержания по порядковой шкале от 0 до 5. Значение 0 соответствует отсутствию признаков вредоносного содержания, а значение 5 - выраженному содержанию с высоким потенциальным риском. Промежуточные значения отражают возрастание выраженности соответствующего признака.

Помимо числовой оценки модель-учитель формирует краткое обоснование решения. Обоснования не используются непосредственно в качестве целевой переменной, однако позволяют контролировать качество автоматической разметки, выявлять неоднозначные случаи и обнаруживать систематические ошибки.

3.5. Оценка образовательной ценности

Методология оценки образовательной ценности в настоящей работе вдохновлена подходом FineWeb-Edu, в котором синтетическая разметка крупной языковой моделью используется для обучения значительно более компактного классификатора. В отличие от

FineWeb-Edu, ориентированного на англоязычный FineWeb и преимущественно на образовательное качество документа, предлагаемый подход применяется к русскоязычной части FineWeb2 и сохраняет набор независимых качественных характеристик, позволяющих формировать различные специализированные коллекции.

Под образовательной ценностью документа понимается степень, в которой содержащийся в нем текст передает содержательные знания, объясняет причинно-следственные связи, обучает некоторому навыку или способствует более глубокому пониманию предметной области. Наличие большого числа фактов само по себе не считается достаточным признаком образовательной ценности. В частности, рекламные материалы, служебные страницы, перечни характеристик и краткие новостные сообщения могут содержать фактическую информацию, но не давать ее объяснения или содержательного обобщения.

Оценка образовательной ценности выполняется по общей схеме переноса разметки от крупной языковой модели к компактной модели-классификатору. На первом этапе крупная языковая модель используется в качестве автоматического аннотатора. Для каждого документа x_i она формирует оценку

$$y_i \in 0, 1, 2, 3, 4, 5, \quad (22)$$

где значение (0) соответствует отсутствию образовательной ценности, а значение (5) - выраженной образовательной ценности. Промежуточные значения отражают степень выраженности соответствующего свойства.

В отличие от обычной многоклассовой классификации, значения шкалы являются упорядоченными: ошибка между оценками (4) и (5) должна считаться менее существенной, чем ошибка между оценками (0) и (5). Поэтому обучение компактной модели формулируется как задача предсказания непрерывной порядковой оценки.

В качестве основы модели используется предварительно обученный трансформерный кодировщик текста, дополненный регрессионной головой с одним выходом. Текст документа токенизируется и ограничивается максимальной длиной входной последовательности модели.

При применении обученной модели к коллекции документов ее предсказание ограничивается диапазоном $[0, 1]$, после чего преобразуется обратно к дискретной шкале:

$$e_{\text{disc}}(x) = \text{round}(5 \cdot f(x)), \quad (23)$$

где

$$\hat{e}_{\text{disc}}(x) \in 0, 1, 2, 3, 4, 5. \quad (24)$$

, а f - компактная модель классификатор.

Сохранение непрерывного значения позволяет не фиксировать единый порог образовательной ценности на этапе разметки корпуса. При формировании конкретной доменной коллекции может быть выбран порог τ_{edu} , соответствующий требованиям к полноте и качеству данных.

Качество модели оценивается как для непрерывных, так и для дискретизированных предсказаний. Для непрерывной оценки применяются средняя абсолютная ошибка и среднеквадратичная ошибка. После округления предсказаний дополнительно могут вычисляться точность классификации и F_1 -мера.

3.6. Дополнительные характеристики документов

Результатом обработки корпуса является не только отнесение документа к одной или нескольким тематикам, но и его дополнение набором характеристик, которые могут использоваться при последующем формировании специализированных обучающих коллекций. Используемые характеристики можно разделить на несколько групп, представленных в таблице 1.

Таблица 1: Группы характеристик документов

Группа	Характеристики	Назначение
Метаинформация	длина текста, URL, домен источника	общая информация о документе
Тематические	множество тематических тегов	определение содержания документа и его общей тематики
Доменные	оценка степени принадлежности к доменной области	отбор документов, которые не удовлетворяют жесткому критерию по тегам, но семантически близки к заданному домену
Полезность	образовательная ценность	оценка содержательности и полезности текста
Риск	оценка потенциально вредного содержания, коммерческая направленность	обнаружение документов, которые могут быть нежелательными либо требуют отдельного режима фильтрации
Качество языка	оценка качества написанного текста с грамматической точки зрения	оценка общего качества построения текста
Надежность информации	экспериментальная метрика, показывающая степень надежности предоставленной информации	показывает, в какой степени можно положиться на информацию, приведенную в документе
Служебные	индекс в коллекции, ключ sha256	обеспечение воспроизводимости обработки и связи предсказаний с исходными документами

Для образовательной ценности и риска потенциально вредного содержания сохраняются как непрерывные, так и дискретные оценки. Наличие нескольких независимых характеристик позволяет задавать состав коллекции в соответствии с конкретным сценарием. Например, множество документов с высокой образовательной ценностью и низким риском вредоносного содержания может быть определено как

$$D_{\text{edu}}(\tau_e, \tau_h) \{d \in D : s_{\text{edu}}(d) \geq \tau_e \wedge s_{\text{harm}}(d) < \tau_h\}, \quad (25)$$

где $s_{\text{edu}}(d)$ и $s_{\text{harm}}(d)$ обозначают нормированные оценки образовательной ценности и потенциально вредного содержания, а τ_e и τ_h являются настраиваемыми порогами.

Аналогично могут задаваться ограничения на тематические теги, принадлежность домену, коммерческую направленность, языковое качество и информационную надежность. Таким образом, итогом работы инструментария является расширенная коллекция с сохраненными характеристиками документов, а не единственная выборка, сформированная с использованием заранее зафиксированных порогов.

4. Доменная коллекция для русского языка

4.1. Данные и параметры классификаторов

Таблица 2: Пример подбора порога для теггера при $k = 3$

Порог	Точность	Полнота	F1
0.00	0.7584	0.5576	0.6427
0.10	0.7604	0.5573	0.6432
0.20	0.7725	0.5544	0.6455
0.25	0.7815	0.5509	0.6463
0.30	0.7920	0.5453	0.6459
0.40	0.8175	0.5279	0.6416
0.50	0.8442	0.4996	0.6277
0.60	0.8757	0.4600	0.6032
0.70	0.9046	0.4070	0.5615

В качестве исходного корпуса использовался раздел `rusCyr1` датасета FineWeb2. Документы группировались по доменам сайтов. Для каждого домена сохранялось не более 10 различных текстов, что позволило получить корпус объемом около 35 млн документов. Ограничение числа документов от одного домена использовалось для уменьшения доминирования крупных сайтов и повышения разнообразия источников в исходной выборке. Тем самым модельная разметка охватывала большее число сайтов, а не концентрировалась на нескольких крупных доменах. Для первичной разметки использовалась крупная языковая модель Qwen3-235B. Модель размечала каждый текст отдельно и присваивала ему ровно 5 тегов в свободной форме. Всего было размечено около 10 тыс. доменов с помощью LLM. В результате было получено около 100 тыс. уникальных исходных тегов.

Для уменьшения размерности исходного пространства свободных тегов применялась кластеризация. Для каждого уникального тега предварительно строилось векторное представление с использованием модели `sergeyzh/BERTA`. Перед вычислением эмбединга из тега удалялся символ `#`, символы подчеркивания заменялись пробелами, а текст приводился к нижнему регистру. Нормализованный тег помещался в шаблон *"Сайт посвящен тегу: <тег>."*

Прямое применение агломеративной кластеризации ко всему множеству, содержащему около 100 тыс. уникальных тегов, является вычислительно затратным. Поэтому использовалась гибридная процедура. На первом этапе из полного множества случайным образом выбирались 10,000 тегов. Для данной подвыборки выполнялась агломеративная кластеризация. Число исходных кластеров задавалось равным 100, что соответствует целевому размеру около 100 уникальных тегов на кластер.

Для каждого полученного кластера вычислялся центроид как нормированная сумма эмбедингов входящих в него тегов. Оставшиеся теги, не вошедшие в исходную выборку из 10,000 элементов, обрабатывались последовательно. Каждый новый тег присоединялся к кластеру, центроид которого имел максимальное косинусное сходство с его эмбедингом. Поскольку все векторные представления и центроиды были нормированы, значение сходства вычислялось как скалярное произведение. После добавления очередного тега центроид соответствующего кластера пересчитывался.

Для ограничения образования чрезмерно крупных и семантически неоднородных кластеров использовался максимальный размер, равный 400 уникальным тегам. При превы-

шении данного значения кластер повторно разделялся методом агломеративной кластеризации. Число подклассов определялось исходя из целевого размера около 100 тегов на кластер.

После распределения всех тегов выполнялась дополнительная постобработка. Для каждого кластера рассчитывалась суммарная частота входящих в него тегов в исходной LLM-разметке. Кластеры с суммарной частотой менее 200 вхождений считались малочастотными и присоединялись к наиболее близкому более частотному кластеру по косинусному сходству их центроидов. Затем дополнительно объединялись кластеры с практически совпадающими центроидами: объединение выполнялось при косинусном сходстве не менее 0.98.

Для каждого итогового кластера определялись десять тегов, эмбединги которых были наиболее близки к его центроиду. Эти теги передавались крупной языковой модели, которая формировала краткое русскоязычное название, обобщающее семантику кластера. Таким образом, название определялось не только наиболее частотным тегом, а на основании набора наиболее репрезентативных относительно центроида элементов кластера. После описанной процедуры из исходного множества приблизительно 100 тыс. свободных тегов было сформировано 788 тематических кластеров, которые далее использовались в качестве фиксированного пространства классов теггера.

Таблица 3: Основные параметры кластеризации тематических тегов

Параметр	Значение
Модель эмбедингов	sergeyzh/BERTA
Размер исходной подвыборки	10,000 тегов
Метрика начальной кластеризации	евклидово расстояние
Начальное число кластеров	100
Целевой размер кластера	100 тегов
Максимальный размер кластера	400 тегов
Метрика присоединения остальных тегов	косинусное сходство
Порог малочастотного кластера	200 вхождений
Порог слияния близких центроидов	0.98
Число тегов для именованя кластера	10
Итоговое число кластеров	788

После объединения близких тегов было получено 788 кластеров. Для каждого кластера модель Qwen выбирала репрезентативное название на основе 10 наиболее частотных тегов внутри кластера. На полученной разметке был обучен многометочный теггер на основе RuModernBERT от VK. Модель возвращала вектор из 788 значений от 0 до 1. Тег присваивался документу, если соответствующее значение превышало выбранный порог. Порог подбирался на обучающей выборке по метрикам precision, recall и F1. Качество оказалось немного ниже в связи с тем, что бралось топ 3 тега, а не топ 5.

Для дальнейших экспериментов использовался порог 0.25, обеспечивший наибольшее значение F1 в приведенной конфигурации.

Качество модели оценки образовательной ценности оценивалось на отложенной выборке. Поскольку целевая оценка задается по упорядоченной шкале от 0 до 5. Дополнительно предсказание округлялось до ближайшего значения шкалы в диапазоне от 0 до 5, после чего вычислялись ассурасу и F1 мера.

Полученная модель достигла MAE, равного 0.532, и MSE, равного 0.597. Таким образом, среднее абсолютное отклонение предсказанной оценки от оценки модели-учителя

составляет около половины пункта по шкале от 0 до 5. После перевода в дискретную шкалу точность классификации составила 0.596, а F1 мера - 0.511. Основные параметры обучения приведены в таблице 4.

Таблица 4: Параметры обучения модели оценки образовательной ценности

Параметр	Значение
Размер коллекции	около 88 тыс. документов
Размер train	около 70 тыс. документов
Максимальная длина входа	8192 токена
Learning rate	$5 \cdot 10^{-5}$
Batch size	4
Gradient accumulation steps	16
Эффективный batch size	64
Функция потерь	BCEWithLogitsLoss
Целевая шкала	0--5

Распределение исходных оценок довольно неравномерное. Наиболее представленным являлся класс 0, содержащий 35,757 документов, тогда как максимальная оценка 5 встречалась только для 2,968 документов. Поэтому основными метриками качества непрерывного предсказания использовались MAE и MSE.




Рис. 1: Матрица ошибок для образовательной ценности

В процессе обучения наблюдалось последовательное снижение MAE, MSE и значения функции потерь на валидационной выборке одновременно с ростом ассурасу и F1-меры. Лучший чекпоинт выбирался по минимальному значению метрики MAE.

Анализ матрицы ошибок показывает, что большинство неточных предсказаний приходится на соседние значения порядковой шкалы. На случайной выборке из 1000 документов абсолютная ошибка не превышала одного пункта для 96,2% примеров. Наиболее выраженное снижение качества наблюдается для максимальной оценки 5, которая одновременно является наиболее редкой в обучающей разметке.

4.2. Анализ качества FineWeb2-rus

Для анализа состава и качества русскоязычной части FineWeb2 были использованы результаты тематического теггера и моделей оценки образовательной ценности, риска потенциально вредного содержания и языкового качества, а также оценка информационной надежности.

Высокое языковое качество означает, что текст по форме соответствует связному и корректно написанному материалу, однако не гарантирует его образовательной ценности или информационной надежности. Аналогично, низкий риск потенциально вредного содержания не означает, что документ полезен для обучения языковой модели. Такое разделение позволяет более детально исследовать структуру исходного веб-корпуса.

Тематическая разметка показывает существенную неоднородность FineWeb2-rus. В среднем документу было присвоено 4,13 тематических тегов, а только около 0,1% документов не получили ни одного тега. Среди наиболее часто встречающихся тематик присутствуют как содержательные предметные области, так и категории, характерные для коммерческого и развлекательного веб-контента. Наиболее частыми тегами оказались **#туризм** (1,58 млн документов), **#онлайн_магазины** (1,47 млн), **#образование_россии** (1,36 млн), **#строительная_отрасль** (1,33 млн) и **#дизайн_интерьера** (1,32 млн). Одновременно значительную частоту имеют **#азартные_игры** (0,99 млн), **#акции_и_скидки** (0,87 млн) и **#эротика** (0,85 млн).

Таким образом, уже тематическая структура показывает, что прохождение документов через стандартный пайплайн очистки FineWeb2 не приводит к формированию корпуса, состоящего преимущественно из содержательных или образовательных материалов. В нем одновременно представлены предметные, информационные, коммерческие, развлекательные и потенциально нежелательные типы веб-контента.

Особенно заметно это различие при рассмотрении образовательной ценности. Среднее значение оценки по коллекции составило 0,252. Только 35,05% документов получили оценку не ниже 0,3, 22,83% не ниже 0,5 и 11,43% не ниже 0,7. При этом 47,52% документов получили значение ниже 0,1. Следовательно, согласно используемому классификатору, высокая образовательная ценность характерна лишь для относительно небольшой части FineWeb2-rus.

В то же время распределение языкового качества существенно отличается. Среднее значение данной характеристики составило 0,634, оценку не ниже 0,5 получили 68,70% документов, а не ниже 0,7 практически половина: 51,43%. Таким образом, значительная часть документов, являющихся достаточно качественными с точки зрения формы и языка, одновременно получает низкую оценку образовательной ценности. Это различие показывает, что языковая корректность текста сама по себе не является достаточным критерием его полезности для формирования обучающего корпуса.

Риск потенциально вредного содержания, напротив, для большей части коллекции оказался низким. Среднее значение характеристики составило 0,061. Оценка не ниже 0,3 наблюдалась у 7,99% документов, не ниже 0,5 у 4,67%, а не ниже 0,7 у 2,81%. Для 84,5% документов значение риска находилось в интервале от 0 до 0,05. Следовательно, наличие

явно нежелательного содержания является заметной, но не основной причиной низкой потенциальной полезности документов FineWeb2-rus. Таким образом, наиболее многочисленную проблемную группу составляют не документы с явно вредоносным содержанием, а относительно безопасные тексты с низкой образовательной ценностью.

Различия становятся еще более выраженными при рассмотрении характеристик внутри отдельных тематик. В таблице 5 представлены несколько характерных тегов.

Таблица 5: Средние значения характеристик для отдельных тематических тегов

Тег	Документов	Edu	Harm	Lang	Reliability
#эволюция	100443	0.701	0.017	0.777	0.653
#медицина	815376	0.389	0.064	0.648	0.501
#образование_россии	1361828	0.325	0.030	0.738	0.606
#юридические_консультации	624260	0.323	0.010	0.697	0.600
#туризм	1582078	0.155	0.008	0.700	0.549
#онлайн_магазины	1467405	0.062	0.035	0.571	0.475

Наблюдаемые различия согласуются с семантикой тематических категорий. Для научных и образовательных тематик характерны сравнительно высокие значения образовательной ценности. Например, среди тегов, представленных не менее чем в 100 тыс. документов, наиболее высокие средние значения данной характеристики наблюдались для тегов **#эволюция** (0,701), **#региональная_история** (0,689), **#физика** (0,664) и **#математическая_логика** (0,633).

При этом большая частота тега не означает высокой полезности соответствующих документов. Например, **#онлайн_магазины** является вторым по частоте тегом коллекции, однако средняя образовательная ценность документов с этим тегом составляет только 0,062. Лишь около 7,6% таких документов имеют образовательную оценку не ниже 0,3, а доля документов с оценкой не ниже 0,7 составляет менее 1%. Аналогичная картина наблюдается для ряда коммерческих и сервисных тематик. Это указывает на значительное присутствие в корпусе текстов, которые могут быть грамматически корректными и безопасными, но имеют ограниченную ценность для сценариев обучения, ориентированных на получение содержательных знаний. Например, это тексты рекламы или другого коммерческого содержания.

Отдельную группу составляют тематики, связанные с потенциально нежелательным контентом. Для тега **#азартные_игры** средний риск вредоносного содержания составляет 0,336, а у 58,7% документов значение превышает 0,3. При этом средняя образовательная ценность таких документов составляет только 0,050. Еще более выраженная картина наблюдается для **#эротика**: средняя оценка образовательной ценности составляет 0,006, а средний риск вредоносного содержания 0,765, 98,2% документов с этим тегом имеют значение риска не ниже 0,3.

Предварительные оценки информационной надежности демонстрируют дополнительную неоднородность корпуса. Среднее значение данной характеристики составило 0,508; 56,96% документов получили значение не ниже 0,5, а 17,55% не ниже 0,7. При этом результаты заметно различаются между тематиками: средняя оценка составляет 0,653 для тега **#эволюция**, 0,606 для **#образование_россии**, 0,475 для **#онлайн_магазины** и 0,261 для **#азартные_игры**.

В совокупности полученные результаты показывают, что FineWeb2-rus представляет собой неоднородную коллекцию, качество которой существенно зависит от рассматриваемой характеристики и тематики документа. Большинство документов не относится к

категории потенциально вредоносных и значительная доля обладает достаточно высоким языковым качеством, однако только меньшая часть корпуса получает высокую образовательную оценку. Кроме того, тематическая разметка выявляет крупные группы коммерческого, развлекательного и нежелательного содержимого. Это подтверждает целесообразность хранения нескольких независимых характеристик документа и последующего формирования обучающих коллекций с учетом требований конкретной предметной области вместо использования единственного универсального критерия качества.

4.3. Распределение документов по набору доменов

В качестве первого примера доменной коллекции была собрана коллекция по юриспруденции. Для этого множество из 788 тегов было проанализировано крупной языковой моделью, которая определила теги, относящиеся к юридическому домену. Предварительно к юридическим было отнесено около 40 тегов. Ручная валидация выполнялась на уровне тематических меток и настройки отдельных критериев отбора; полноценная экспертная оценка сформированных доменных коллекций остается направлением дальнейшей работы.

Документ включался в юридическую коллекцию, если выполнялось хотя бы одно из двух условий:

1. документ имел не менее трех тегов из юридического множества;
2. документ содержит от 1 до 2 юридических тегов и семантическое сходство между текстовым описанием тегов документа и запросом *"Тексты про юриспруденцию, законы, суды и т.д."* превышало 0.39.

Для вычисления эмбедингов использовалась модель *sergeyzh/BERTA*. Порог семантического сходства $\tau_{\text{sem}} = 0,39$ был выбран эмпирически на основе ручного анализа примеров из пограничной группы документов, содержащих небольшое число доменных тегов. Для нескольких значений порога оценивалась релевантность отобранных текстов юридической предметной области. При снижении порога в выборку начинало попадать заметное число тематически смежных, но непосредственно не относящихся к юриспруденции документов, тогда как его повышение приводило к исключению релевантных текстов с менее выраженной тематической принадлежностью. Значение 0,39 было выбрано как практический компромисс между этими двумя типами ошибок.

В результате было получено около 3 млн документов юридической тематики.

4.4. Распределение дополнительных характеристик документов

Тематические и модельные характеристики были рассчитаны для русскоязычной коллекции, содержащей 35,617,902 документа. Тематический словарь включал 788 тегов. Среднее число тегов на документ составило 4,13. В таблице 6 представлено распределение количества тегов по всей коллекции.

Образовательная ценность и риск потенциально вредного содержания были рассчитаны для всей коллекции. Доменная оценка и семантическая близость представлены отдельно для сформированной юридической коллекции.

Оценку ниже 0,1 получили 47,5% документов, а значение ниже 0,3 наблюдалось для 65,0% коллекции. В то же время 22,8% документов получили оценку не ниже 0,5, а 11,4%

Таблица 6: Распределение числа тегов на документ после применения теггера

Число тегов	Число документов	Доля
0	36689	0.1%
1	846632	2.4%
2	3869365	10.9%
3	8008849	22.5%
4	9365606	26.3%
5	7223097	20.3%
6	3962951	11.1%
7	1609156	4.5%
8	516997	1.5%
9	137853	0.4%
10	32381	0.1%
≥ 11	8326	0.02%

Таблица 7: Доли документов, превышающих заданные пороги

Характеристика	$\geq 0,3$	$\geq 0,5$	$\geq 0,7$
Образовательная ценность	35,05	22,83	11,43
Риск вредоносного содержания	7,99	4,67	2,81

не ниже 0,7. Таким образом, классификатор выделяет сравнительно небольшое подмножество документов с высокой предполагаемой образовательной ценностью.

Для оценки потенциально вредного содержания распределение следующее: 86,4% документов получили значение ниже 0,1, а не ниже 0,7 - 2,81%. Следовательно, классификатор выделяет относительно небольшую группу документов с повышенным риском нежелательного содержания.

Между документами с высокой образовательной ценностью и риском вредоносного контента существует слабая отрицательная корреляция -0.19 . Она показывает, что документы с высокой оценкой вредоносного содержания в среднем имеют более низкую образовательную оценку. Совместное применение характеристик позволяет формировать различные варианты коллекции. Примеры таких выборок представлены в таблице 8. Строки таблицы описывают отдельные сценарии фильтрации и не образуют полного разбиения корпуса.

Таблица 8: Примеры отбора документов по двум модельным характеристикам

Условие	Документов
Образовательная ценность $> 0,7$, риск $< 0,3$	4,038,903
Образовательная ценность $> 0,5$, риск $< 0,3$	8,023,315
Образовательная ценность $< 0,3$, риск $< 0,3$	20,532,230
Образовательная ценность $< 0,3$, риск $> 0,7$	985,261

Полученные результаты демонстрируют, что тематической принадлежности и одного общего показателя качества недостаточно для формирования обучающего корпуса. Большинство документов имеет низкий риск вредоносного содержания, но при этом также низкую образовательную ценность. Напротив, подмножество документов, одновременно имеющих высокую образовательную ценность и низкую оценку риска, составляет только

около одной девятой исходной коллекции.

4.5. Сравнение распределений образовательной ценности для топовых моделей

Поскольку состав предобучающих данных используемых закрытых и открытых LLM не всегда полностью известен, нельзя исключить частичное пересечение веб-документов корпуса с их обучающими данными. Для снижения зависимости результатов от особенностей конкретной модели-учителя дополнительно сравниваются оценки нескольких современных LLM.

5. Ограничения

На текущем этапе качество некоторых этапов пайплайна оценивалось преимущественно автоматически или путем предварительного просмотра результатов. В частности, требуется дополнительная ручная валидация качества доменного отбора, качества теггера и оценок образовательной ценности. Также необходимо более строго обосновать выбор порогов для семантического сходства и для классификаторов.

6. Заключение

В статье предложен пайплайн формирования доменно-ориентированных обучающих коллекций, основанный на разметке крупной языковой моделью, кластеризации свободных тегов, обучении компактных классификаторов и последующем масштабировании разметки на большой веб-корпус. На примере русскоязычного корпуса FineWeb2 показано, что такой подход позволяет получать доменные коллекции с дополнительными признаками полезности и надежности документов.

Список литературы

- [1] L. Gao et al. *The Pile: An 800GB Dataset of Diverse Text for Language Modeling*. 2020. <https://arxiv.org/abs/2101.00027>
- [2] J. Abadji et al. *Towards a Cleaner Document-Oriented Multilingual Crawled Corpus*. 2022. <https://aclanthology.org/2022.lrec-1.463/>
- [3] G. Penedo et al. *The RefinedWeb Dataset for Falcon LLM: Outperforming Curated Corpora with Web Data, and Web Data Only*. 2023. <https://arxiv.org/abs/2306.01116>
- [4] T. Nguyen et al. *CulturaX: A Cleaned, Enormous, and Multilingual Dataset for Large Language Models in 167 Languages*. 2024. <https://aclanthology.org/2024.lrec-main.377/>
- [5] Penedo, Guilherme, et al. "The fineweb datasets: Decanting the web for the finest text data at scale." *Advances in Neural Information Processing Systems* 37 (2024): 30811-30849.
- [6] Penedo, Guilherme, et al. "FineWeb2: One Pipeline to Scale Them All--Adapting Pre-Training Data Processing to Every Language." (2025).