Формирование доверенных коллекций для обучения больших языковых моделей для русского языка

Григорьев Д. А., Чернышев Д. И.

09.09.2026

Аннотация

Качество данных предварительного обучения является определяющим фактором эффективности больших языковых моделей, однако доступные многоязычные веб-корпуса преимущественно ориентированы на общую фильтрацию без предметной специализации. Отсутствие единого набора независимых признаков — тематической принадлежности, образовательной ценности, информационной надежности и потенциальных рисков — затрудняет воспроизводимое формирование специализированных обучающих коллекций для русского языка. В работе предложена масштабируемая методология аннотирования веб-данных: открытые тематические теги языковой модели кластеризуются в фиксированный словарь из более 700 классов, после чего компактные модели обучаются многометочной классификации и оценке качественных характеристик. Подход применен к русскоязычной части корпуса FineWeb2 объемом 35,6 миллиона документов с сохранением независимых оценок по каждому параметру. Анализ показал, что высокое языковое качество не гарантирует образовательной ценности текстов, а документы с высокой полезностью и низким риском составляют лишь около одной девятой части коллекции. Исследование согласованности выявило, что различные языковые модели демонстрируют высокую ранговую корреляцию при оценке образовательной ценности, но существенно расходятся в абсолютных баллах. Обучение моделей архитектуры Qwen3 размером от 100 до 500 миллионов параметров с нуля на 11 миллиардах токенов продемонстрировало, что образовательный отбор дает наибольший выигрыш для модели на 300 миллионов параметров, улучшая вероятность правильного ответа на 12 из 15 задач бенчмарка LLMTF, однако величина эффекта немонотонно зависит от масштаба архитектуры.

1. Введение

Качество данных предварительного обучения является одним из ключевых факторов, определяющих эффективность больших языковых моделей. В последние годы появилось множество крупных открытых корпусов, однако большинство из них ориентированы на английский язык или предлагают лишь общую фильтрацию качества, без привязки к предметным областям. При этом методология формирования обучающих коллекций даже наиболее успешных открытых моделей часто оказывается закрыта или не раскрывает детали влияния отдельных элементов алгоритма подготовки данных на качество итоговой коллекции. Низкая доступность данных и невоспроизводимость методологии их сбора затрудняют разработку моделей на других языках, включая русский язык.

В работе предлагается методология формирования обучающих коллекций с заданными требованиями к тематике и качеству документов. Большая языковая модель размечает ограниченную подвыборку текстов, после чего свободные тематические теги объединяются в фиксированный словарь классов. По полученной разметке обучаются компактный теггер и модели оценки качества, которые применяются ко всей исследуемой коллекции. Сохраненные метки и оценки позволяют изменять условия отбора без повторной разметки текстов.

Основное внимание уделяется анализу качества русскоязычных данных FineWeb2. Исследуются тематический состав коллекции, распределения образовательной ценности, риска потенциально вредного содержания, качества языка и предполагаемой информационной надежности. Анализ показывает, как модельные оценки различаются между тематиками и как сочетание условий по нескольким характеристикам меняет состав отбираемых данных. Применение методологии рассматривается на примере юридической и медицинской коллекций.

Дополнительно исследуется согласованность образовательных оценок разных LLM и влияние отбора по образовательной ценности на обучение малых языковых моделей с нуля.

2. Литературный обзор

Качество данных для предварительного обучения больших языковых моделей является критическим фактором, определяющим их итоговую производительность. За последние годы был предложен ряд крупных открытых корпусов, различающихся по источникам, объему и методам очистки.

Ранние работы, такие как **The Pile** [1] предложили подход, основанный на агрегации множества разнородных источников. Он представляет собой англоязычный корпус объемом около 825 ГБ, объединяющий научные статьи, книги, программный код, судебные документы и веб-страницы. Разделение данных в нем определяется источником происхождения, а не содержательными характеристиками отдельных документов. **OSCAR** [2] сделал шаг в сторону автоматической фильтрации веб-контента из Common Crawl и ориентирован на построение крупных многоязычных корпусов с автоматическим определением языка и базовой фильтрацией веб-текстов. В более поздних версиях обработка была перенесена с отдельных строк на целые документы, а корпус дополнен метаданными о качестве и потенциально нежелательном содержании.

RefinedWeb [3] демонстрирует, что тщательно очищенные веб-данные могут быть конкурентоспособны по отношению к корпусам, составленным из множества специализированных источников. Его обработка включает извлечение основного текста, языковую фильтрацию и удаление низкокачественных документов. **CulturaX** [4] развивает подходы к масштабируемой очистке многоязычных веб-корпусов. Набор данных построен на основе mC4 и OSCAR и содержит более 6 трлн токенов для 167 языков. Его обработка включает языковую идентификацию, фильтрацию URL, очистку на основе текстовых метрик и дедупликацию, а пороги фильтрации определяются отдельно для каждого языка.

FineWeb [5] продолжает развитие подходов к созданию крупных корпусов на основе Common Crawl. Набор данных содержит около 15 триллионов токенов, полученных из Common Crawl. Авторы подробно исследуют влияние отдельных этапов обработки, включая дедупликацию, фильтрацию низкокачественных документов и удаление нежелательного содержимого. На основе FineWeb также была сформирована коллекция **FineWeb-Edu**, содержащая тексты с высокой образовательной ценностью. Для ее построения ис-

пользовалась модельная оценка качества документов, что позволило выделить около 1,3 трлн токенов образовательного содержания.

FineWeb2 [6] адаптирует предложенный в FineWeb процесс обработки для многоязычных веб-данных. Полученный корпус занимает около 20 ТБ, содержит примерно 5 млрд документов и охватывает более 1000 языков. FineWeb2 представляет собой один из наиболее масштабных открытых многоязычных корпусов, однако его разметка также в первую очередь ориентирована на общее качество документов, а не на их принадлежность конкретным предметным областям.

Подготовка коллекций для русского языка также рассматривается в работах о **T-pro**, **GigaChat** и **Vikhr**. В отчете о T-pro [7] описано продолженное предобучение моделей Qwen2.5 на смеси очищенных веб-страниц, книг, кода и других источников: при подготовке данных выполняется перебалансировка тематик и стилей документов. Для GigaChat [8] формируется многоязычная коллекция из веб-текстов, высококачественных публикаций, кода и синтетических данных. LLM и специализированные модели используются для выделения образовательного и информационно насыщенного содержания. В Vikhr [9] русскоязычные данные для продолженного предобучения дедуплицируются и фильтруются компактной моделью RuBERT-tiny, обученной на оценках GPT-4-turbo по информативности, образовательности, языковому качеству, стилю и безопасности. Эти работы показывают применение тематического балансирования и модельных оценок при подготовке данных для российских LLM. В настоящей работе дополнительно исследуется построение тематического словаря по свободным тегам и последующий отбор предметных коллекций по сочетанию сохраненных характеристик.

Рассмотренные работы демонстрируют постепенный переход от объединения заранее выбранных источников к масштабируемой автоматической очистке и модельной оценке качества веб-документов. При этом содержательная принадлежность документа к предметной области, его образовательная ценность, надежность и потенциальные риски обычно не представлены в виде единого набора признаков. Это ограничивает возможности формирования специализированных обучающих коллекций с заданными требованиями к тематике и качеству содержимого.

3. Методология формирования доменных коллекций

3.1. Общая схема обработки

На вход метода поступает коллекция веб-документов. Тексты группируются по сайтам, после чего формируется подвыборка для первичной разметки. LLM присваивает каждому выбранному документу свободные тематические теги и оценки качества. Свободные теги нормализуются и объединяются в кластеры, которые задают выходные классы компактного теггера. Отдельные компактные модели обучаются воспроизводить качественные оценки LLM.

После применения моделей к полной коллекции для каждого документа сохраняются тематические метки и числовые характеристики. Кроме тематических тегов, каждому документу могут быть присвоены дополнительные характеристики, в том числе оценка образовательной ценности, токсичности и другие признаки, полезные при отборе данных для обучения языковых моделей. Полученные предсказания используются для формирования коллекций, относящихся к заданным предметным областям. Предметная область задается через набор тегов и текстовое описание, а требования к качеству - через пороги отдельных оценок.

3.2. Обучение теггера

Пусть $\mathcal{D}_{\text{ann}} = \{x_1, \ldots, x_{N_{\text{ann}}}\}$ - подвыборка для первичной разметки. Для документа x_n модель M с инструкцией q формирует m свободных тегов:

$$T(x_n) = M(x_n; q) = \{t_{n1}, \ldots, t_{nm}\}. \tag{1}$$

где q - инструкция для модели, а t_{nj} - свободный текстовый тег, описывающий одну из тем документа. Для получения более контролируемых результатов производилось несколько запусков LLM на каждый сайт и выбирался наиболее частый ответ.

Теги описывают несколько тем одного документа без заранее заданной таксономии. Такая разметка содержит синонимы, разный уровень обобщения и вариации записи, поэтому перед обучением классификатора ее необходимо привести к фиксированному пространству меток.

Перед построением фиксированного пространства классов выполняется нормализация тегов. Нормализация включает приведение к единому регистру, удаление лишних пробелов и специальных символов, унификацию разделителей и исключение дубликатов внутри одного документа. После нормализации формируется множество уникальных свободных тегов $\mathcal{U}$.

Размер множества $\mathcal{U}$ может быть существенно больше числа тематических классов, необходимого для обучения классификатора. Например, теги, обозначающие одну предметную область, могут отличаться порядком слов, используемой терминологией или уровнем обобщения. Для преобразования открытого пространства тегов в конечную таксономию применяется их семантическая кластеризация. Для каждого уникального нормализованного тега $u \in \mathcal{U}$ строится единичный вектор:

$$\mathbf{e}_u = \frac{E(u)}{\|E(u)\|_2}, \qquad s(u_i, u_j) = \mathbf{e}_{u_i}^{\mathsf{T}} \mathbf{e}_{u_j}, \tag{2}$$

где E - модель эмбеддингов. Нормировка позволяет вычислять косинусное сходство скалярным произведением.

Чтобы не строить матрицу попарных расстояний для всего словаря, агломеративная кластеризация применяется к ограниченной случайной подвыборке $\mathcal{U}_0$. В результате формируется начальное множество кластеров K_0.

Оставшиеся теги последовательно присоединяются к ближайшему нормированному центроиду:

$$c(u) = \arg\max_{1 \le k \le K_{\text{cur}}} \mathbf{e}_u^{\mathsf{T}} \boldsymbol{\mu}_k, \qquad \boldsymbol{\mu}_k = \frac{\sum_{v \in C_k} \mathbf{e}_v}{\| \sum_{v \in C_k} \mathbf{e}_v \|_2}. \tag{3}$$

После присоединения тега соответствующий центроид обновляется. Чрезмерно крупные кластеры дополнительно разделяются повторной агломеративной кластеризацией, а малые кластеры объединяются с ближайшим соседом по центроиду.

Для именования итогового кластера C_k в LLM передаются теги, ближайшие к его центроиду. Полученное название v_k задает один из K классов словаря $\mathcal{V} = \{v_1, \ldots, v_K\}$. Замена свободных тегов названиями соответствующих кластеров дает целевую разметку:

$$\begin{aligned} \varphi(u) &= v_{c(u)}, \qquad T^*(x) = \{\varphi(u) : u \in T(x)\}, \\ y_n &= (y_{n1}, \ldots, y_{nK}) \in \{0,1\}^K, \\ y_{ni} &= \mathbb{I}[v_i \in T^*(x_n)]. \end{aligned} \tag{4}$$

где y_n - бинарный вектор целевых меток.

Один документ может иметь несколько меток, поэтому теггер решает задачу многометочной классификации. Предварительно обученный кодировщик с линейным выходным слоем возвращает логиты $\mathbf{z}(x) = F(x)$, из которых получаются оценки принадлежности классам:

$$p_i(x) = \sigma(z_i(x)), \qquad \widehat{T}(x;\tau) = \{v_i \in \mathcal{V} : p_i(x) > \tau\}. \tag{5}$$

Снижение порога увеличивает число присваиваемых тегов и полноту разметки, но одновременно повышает число ложноположительных предсказаний. Повышение порога, напротив, увеличивает точность, но приводит к потере менее выраженных тематик. Поэтому значение τ подбирается на отложенной выборке, по precision, recall и F_1.

Предложенная методология преобразует открытую тематическую разметку языковой модели в фиксированное пространство из многих меток. Основная часть корпуса обрабатывается компактным теггером, что снижает вычислительную стоимость разметки.

3.3. Определение предметной принадлежности документа

Для предметной области Ω задаются множество тематических меток $T_\Omega \subseteq \mathcal{V}$ и текстовое описание q_Ω. Число совпадений с предсказанными тегами документа равно

$$n_\Omega(x) = |\widehat{T}(x;\tau) \cap T_\Omega|. \tag{6}$$

Если совпадений недостаточно для прямого включения документа, дополнительно сравниваются описание области и текстовое представление всех присвоенных документу тегов. Пусть $g(\widehat{T}(x;\tau))$ обозначает объединение названий этих тегов в строку. Тогда

$$s_\Omega(x) = \cos\Big(E(q_\Omega), E(g(\widehat{T}(x;\tau)))\Big). \tag{7}$$

Документ включается в предметную коллекцию X_Ω, если выполнено одно из условий:

$$x \in X_\Omega \iff n_\Omega(x) \geq m \ \vee \ \big(1 \leq n_\Omega(x) < m \ \wedge \ s_\Omega(x) > \tau_{\text{sem}}\big). \tag{8}$$

Первое условие использует число предметных тегов, второе расширяет отбор за счет семантически близких сочетаний меток. Документы без единого совпадения с T_Ω в такую коллекцию не попадают.

3.4. Оценка риска потенциально вредного содержания

Эта характеристика отражает выраженность агрессивной риторики, оскорблений, языка ненависти, описания или пропаганды опасных действий и другого содержания, которое может требовать отдельного режима фильтрации.

Качественные характеристики получаются по общей схеме: LLM присваивает документу оценку по порядковой шкале от 0 до 5 и кратко обосновывает ответ; компактная модель обучается на этой разметке и применяется к полной коллекции. Обоснования используются при предварительном просмотре разметки. Для риска значение 0 соответствует отсутствию выраженных признаков вредного содержания, значение 5 - их высокой выраженности. Итоговый непрерывный выход сохраняется в диапазоне $[0, 1]$.

3.5. Оценка образовательной ценности

Под образовательной ценностью понимается способность текста передавать знания, объяснять связи между явлениями, помогать освоению навыка или пониманию предметной области. Большое число фактов без объяснения и контекста само по себе не считается достаточным признаком. Например, перечень характеристик товара может содержать точные сведения, но не давать содержательного объяснения.

Перенос разметки от LLM к компактному классификатору следует схеме FineWeb-Edu [5]. В настоящей работе образовательная оценка применяется к русскоязычным документам FineWeb2 и сохраняется вместе с другими характеристиками, без сведения их к общему баллу. LLM задает исходную метку $y_{\text{edu}}(x) \in \{0, 1, 2, 3, 4, 5\}$. В отличие от обычной многоклассовой классификации, значения шкалы являются упорядоченными: ошибка между оценками (4) и (5) должна считаться менее существенной, чем ошибка между оценками (0) и (5). Компактная модель предсказывает непрерывное значение, по которому можно измерять величину отклонения от оценки учителя. Перед вычислением функции потерь BCEWithLogitsLoss целевые оценки переводятся в диапазон $[0, 1]$: $\widetilde{y}_{\text{edu}}(x) = y_{\text{edu}}(x)/5$.

Кодировщик текста дополняется одним выходом $z_{\text{edu}}(x)$. При применении модели нормированная и дискретная оценки имеют вид

$$s_{\text{edu}}(x) = \sigma(z_{\text{edu}}(x)) \in [0, 1], \qquad \widehat{y}_{\text{edu}}(x) = \text{round}(5 s_{\text{edu}}(x)) \in \{0, 1, 2, 3, 4, 5\}. \tag{9}$$

Непрерывная оценка используется для отбора с настраиваемым порогом. Качество воспроизведения учителя оценивается с помощью MAE и MSE на шкале 0--5; для округленного предсказания дополнительно вычисляются доля точных совпадений и F_1.

3.6. Оценка качества языка

Качество языка характеризует связность, грамматическую корректность и естественность текста. LLM оценивает эти признаки по общей схеме, после чего компактная модель переносит оценки на коллекцию. Выход сохраняется в диапазоне $[0, 1]$. Данная характеристика описывает форму изложения: грамматически корректный текст может иметь любую предметную принадлежность и низкую образовательную оценку. Поэтому условия по качеству языка задаются отдельно от образовательного фильтра.

3.7. Оценка информационной надежности

Оценка предполагаемой информационной надежности отражает, насколько текст выглядит обоснованным и последовательным в пределах доступного модели контекста. Она также получается переносом разметки LLM на компактную модель и сохраняется как значение в диапазоне $[0, 1]$.

Модель не проверяет утверждения по внешним источникам. Поэтому высокий балл означает наличие текстовых признаков предполагаемой надежности, а не подтвержденную фактическую корректность.

Выделение информационной надежности в отдельный признак позволяет не смешивать ее с образовательной ценностью. Текст может быть подробно и последовательно написан, но содержать сомнительные утверждения; и наоборот, краткий справочный материал может обладать низкой образовательной ценностью, но высокой предполагаемой надежностью.

3.8. Дополнительные характеристики документов

Для каждого документа сохраняются исходные метаданные, тематические предсказания и отдельные качественные оценки, указанные в таблице 1. Предметная принадлежность вычисляется относительно заданной области, тогда как оценки качества могут использоваться в разных сценариях отбора.

Таблица 1: Группы характеристик документов

Группа	Характеристики	Назначение
Метаинформация	длина текста, URL, домен источника	общая информация о документе
Тематические	множество тематических тегов	определение содержания документа и его общей тематики
Доменные	оценка степени принадлежности к доменной области	отбор документов, которые не удовлетворяют жесткому критерию по тегам, но семантически близки к заданному домену
Полезность	образовательная ценность	оценка содержательности и полезности текста
Риск	оценка потенциально вредного содержания	обнаружение документов, которые могут быть нежелательными либо требуют отдельного режима фильтрации
Качество языка	оценка качества написанного текста с грамматической точки зрения	оценка общего качества построения текста
Надежность информации	экспериментальная метрика, показывающая степень надежности предоставленной информации	показывает, в какой степени можно положиться на информацию, приведенную в документе
Служебные	индекс в коллекции, ключ sha256	обеспечение воспроизводимости обработки и связи предсказаний с исходными документами

Раздельное хранение оценок позволяет задавать несколько условий одновременно. Например, из полной исследуемой коллекции $\mathcal{D}_{\text{full}}$ можно выделить документы с высокой образовательной оценкой и низким модельным риском:

$$\mathcal{D}_{\text{edu}}(\tau_e, \tau_h) = \{x \in \mathcal{D}_{\text{full}} : s_{\text{edu}}(x) > \tau_e \ \wedge \ s_{\text{harm}}(x) < \tau_h\}. \tag{10}$$

Аналогично добавляются условия по предметной принадлежности, качеству языка или предполагаемой надежности. Пороги определяют конкретную подвыборку, но не изменяют сохраненную разметку полной коллекции.

4. Доменная коллекция для русского языка

4.1. Данные и параметры классификаторов

Исходными данными служил раздел `rus_Cyrl` FineWeb2. Для каждого сайта сохранялось не более десяти различных текстов. Полученная коллекция содержит 35 617 902 документа.

Для первичной разметки было выбрано около 100 тыс. текстов примерно с 10 тыс. сайтов. Модель `Qwen3-235B-A22B-Instruct` присваивала каждому тексту ровно пять свободных тегов. После нормализации было получено около 100 тыс. уникальных тегов.

Эмбеддинги тегов вычислялись моделью `sergeyzh/BERTA`. Из тега удалялся символ #, подчеркивания заменялись пробелами, текст приводился к нижнему регистру и помещался в шаблон «Сайт посвящен тегу: <тег>.». Полученные векторы нормировались по евклидовой норме. Начальная агломеративная кластеризация выполнялась для 10 000 случайно выбранных тегов с разбиением на 100 кластеров.

Остальные теги присоединялись последовательно по косинусному сходству с обновляемыми центроидами. При превышении 400 тегов кластер разделялся с целевым размером около 100 тегов. Затем группы с суммарной частотой менее 200 вхождений в исходной разметке присоединялись к ближайшим более частотным группам. Кластеры с косинусным сходством центроидов не менее 0,98 также объединялись. Для названия каждой группы в LLM передавались десять ближайших к центроиду тегов. Итоговый словарь содержит 788 классов.

По преобразованной разметке обучался теггер на основе RuModernBERT от VK. Порог выбирался на отложенной выборке: в диагностическом эксперименте сохранялись не более трех наиболее вероятных тегов, дополнительно удовлетворяющих порогу. Наибольшая F_1-мера в этом режиме получена при пороге 0,25, что показано в таблице 2. После выбора порог фиксировался, и при разметке всей коллекции сохранялись все теги с оценкой выше 0,25 без ограничения top-3.

Таблица 2: Согласие теггера с разметкой учителя при ограничении top-3

Порог	Precision	Recall	F_1
0.00	0.7584	0.5576	0.6427
0.10	0.7604	0.5573	0.6432
0.20	0.7725	0.5544	0.6455
0.25	0.7815	0.5509	0.6463
0.30	0.7920	0.5453	0.6459
0.40	0.8175	0.5279	0.6416
0.50	0.8442	0.4996	0.6277
0.60	0.8757	0.4600	0.6032
0.70	0.9046	0.4070	0.5615

Для обучения образовательной оценки использовалось около 88 тыс. документов, из которых около 70 тыс. входило в обучающую часть. Максимальная длина входа составляла 8192 токена, learning rate - $5 \cdot 10^{-5}$, эффективный batch size - 64. В качестве функции потерь использовалась BCEWithLogitsLoss с целевыми оценками, нормированными в диапазон $[0, 1]$. На обучающей выборке MAE относительно разметки учителя составила 0,532, MSE - 0,597 на шкале 0--5. После округления предсказаний до целых значений шкалы доля точных совпадений составила 0,596, F_1 - 0,511.

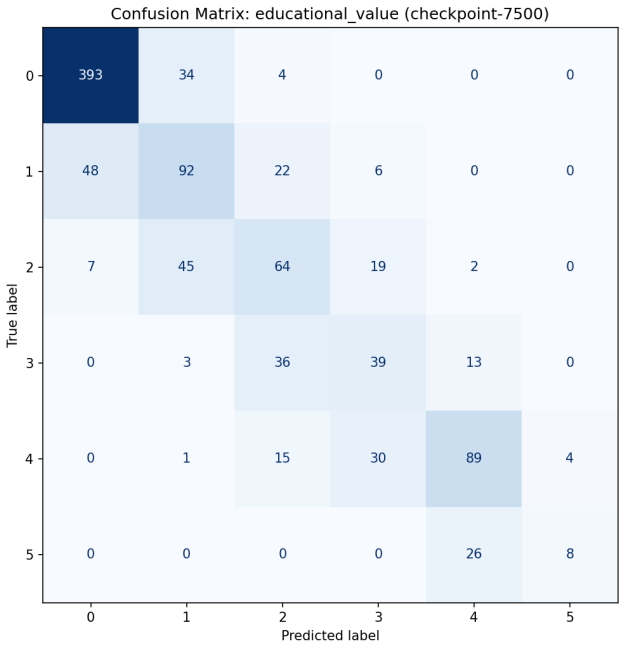


Рис. 1: Сопоставление округленных образовательных оценок модели с метками LLM-учителя на случайной выборке 1000 документов

Исходные оценки распределены неравномерно: значение 0 получили 35 757 документов, значение 5 - 2 968. Для выбора чекпоинта использовалась минимальная MAE. Матрица ошибок на рисунке 1 показывает распределение округленных предсказаний относительно меток учителя для 1000 документов. На этой случайной выборке абсолютное отклонение не превышает одного пункта в 96,2% случаев. Максимальный уровень шкалы распознается хуже соседних уровней; он также редко встречается в обучающей разметке.

4.2. Анализ качества FineWeb2-rus

Далее исследуемую коллекцию обозначаем FineWeb2-rus. Ее качество оценивалось по четырем характеристикам: образовательной ценности, риску вредного содержания, качеству языка и предполагаемой информационной надежности.

Значительная часть документов получает низкую образовательную оценку. Среднее значение Edu составило 0,252; ниже 0,1 находилось 47,52% документов. Оценку не ниже 0,5 получили 22,83%, не ниже 0,7 - 11,43%.

Распределение языкового качества отличается: среднее значение Lang равно 0,634, а оценку не ниже 0,5 получили 68,70% документов, не ниже 0,7 - 51,43%. При этом образовательный фильтр при том же пороге оставляет 22,83% документов. Поэтому языковая фильтрация сама по себе не задает требуемый уровень образовательной оценки.

Для большинства документов модельный риск оказался низким: среднее значение Harm составило 0,061; в интервал $[0; 0{,}05]$ попало 84,5% документов, ниже 0,1 - 86,4%. Оценку не ниже 0,7 получили 2,81%. При этом больше половины коллекции одновременно имеет низкую образовательную оценку и низкий риск, что продемонстрировано в таблице 5. Следовательно, исключение потенциально вредного содержания сохраняет большую группу текстов, которые требуют дополнительного отбора для образовательного сценария.

Тематическая разметка позволяет установить, как эти характеристики различаются

между группами документов. В среднем документ получил 4,13 тематических тега; около 0,1% документов не получили ни одного. Наиболее частыми оказались #туризм (1,58 млн документов), #онлайн_магазины (1,47 млн), #образование_россии (1,36 млн), #строительная_отрасль (1,33 млн) и #дизайн_интерьера (1,32 млн). Значительную частоту имеют также #азартные_игры (0,99 млн), #акции_и_скидки (0,87 млн). Теги могут пересекаться, поэтому частоты не образуют разбиения коллекции.

В таблице 3 приведены средние оценки для нескольких тематик. Обозначения Edu, Harm, Lang и Reliability соответствуют образовательной ценности, риску потенциально вредного содержания, качеству языка и предполагаемой информационной надежности. Все оценки нормированы в диапазон $[0, 1]$.

Таблица 3: Средние значения характеристик для отдельных тематических тегов

Тег	Документов	Edu	Harm	Lang	Reliability
#эволюция	100443	0.701	0.017	0.777	0.653
#медицина	815376	0.389	0.064	0.648	0.501
#образование_россии	1361828	0.325	0.030	0.738	0.606
#юридические_консультации	624260	0.323	0.010	0.697	0.600
#туризм	1582078	0.155	0.008	0.700	0.549
#онлайн_магазины	1467405	0.062	0.035	0.571	0.475

Среди тегов с не менее чем 100 тыс. документов высокие средние образовательные оценки наблюдались для #эволюция (0,701), #региональная_история (0,689), #физика (0,664) и #математическая_логика (0,633). Для одного из самых частых тегов, #онлайн_магазины, средняя оценка составила 0,062; оценку не ниже 0,3 получили около 7,6% документов, не ниже 0,7 - менее 1%. Другой пример - #туризм: среднее языковое качество составляет 0,700, а образовательная оценка - 0,155. Таким образом, тематический разрез показывает, в каких группах высокая оценка формы изложения сочетается с низкой образовательной оценкой.

Для #азартные_игры средний риск составил 0,336; у 58,7% документов он превышал 0,3, при средней образовательной оценке 0,050. Для #эротика средние значения Edu и Harm составили 0,006 и 0,765; риск не ниже 0,3 получили 98,2% документов.

Для предполагаемой информационной надежности среднее значение по коллекции равно 0,508; оценку не ниже 0,5 получили 56,96% документов, не ниже 0,7 - 17,55%. Средние значения различаются между темами: 0,653 для #эволюция, 0,606 для #образование_россии, 0,475 для #онлайн_магазины и 0,261 для #азартные_игры.

В совокупности результаты показывают неоднородность FineWeb2-rus как источника обучающих данных: низкий модельный риск и высокое языковое качество широко распространены, а высокие образовательные оценки встречаются у меньшей доли документов. Тематические группы также заметно различаются по сочетанию этих характеристик. Поэтому для формирования предметной обучающей коллекции важно учитывать как содержание текста, так и требования к его качеству.

4.3. Распределение документов по набору доменов

Для иллюстрации предметного отбора рассмотрены две коллекции: юридическая и медицинская. Принадлежность предметной области определяется по тематическим тегам и дополнительному семантическому условию, описанным в разделе 3.3.

Для юридической коллекции из словаря 788 классов с помощью LLM были выбраны около 40 тегов. Документ включался при наличии не менее трех юридических тегов либо при одном или двух таких тегах и косинусном сходстве выше 0,39 между строкой тегов и запросом «Тексты про юриспруденцию, законы, суды и т.д.». Эмбеддинги вычислялись моделью `sergeyzh/BERTA`; порог выбирался по ручному просмотру пограничных примеров. Полученная юридическая коллекция содержит около 3 млн документов.

Для медицинской коллекции использовались те же условия отбора: не менее трех предметных тегов либо один или два тега при семантическом сходстве выше 0,39; эмбеддинги также вычислялись моделью `sergeyzh/BERTA`. Коллекция, основанная на 50 отобранных тегах, содержит 4 304 119 документов. Не менее трех предметных тегов имеют 2 044 964 документа (47,5%), один или два - 2 259 155 (52,5%). Среди наиболее частых тегов: `#здоровье` (24,8% документов), `#медицина` (18,9%), `#правильное_питание` (11,2%), `#здравоохранение` (9,8%) и `#реабилитация` (9,8%). Доли могут пересекаться, поскольку документ может иметь несколько тематических меток.

Внутри медицинской коллекции 1 493 559 документов (34,7%) получили дискретную образовательную оценку от 3 до 5, а 1 391 970 (32,3%) - оценку 0.

Полноценная экспертная валидация сформированных предметных коллекций в настоящей работе не проводилась. Ручная проверка использовалась при просмотре тематических меток и настройке отдельных условий отбора. В частности, порог семантического сходства 0,39 для юридической коллекции выбран эмпирически по пограничным примерам. Для оценки точности и полноты такого отбора и более строгого выбора порога требуется отдельная выборка с экспертной разметкой.

4.4. Распределение дополнительных характеристик документов

Распределение числа тегов при пороге 0,25 без ограничения top-3 показано в таблице 4. Наиболее частое число меток - четыре (26,3% документов).

Таблица 4: Распределение числа тегов на документ после применения теггера

Число тегов	Число документов	Доля
0	36689	0.1%
1	846632	2.4%
2	3869365	10.9%
3	8008849	22.5%
4	9365606	26.3%
5	7223097	20.3%
6	3962951	11.1%
7	1609156	4.5%
8	516997	1.5%
9	137853	0.4%
10	32381	0.1%
≥ 11	8326	0.02%

Корреляция образовательной оценки и оценки риска по документам составила $-0{,}19$. Совместное применение характеристик позволяет формировать различные варианты коллекции. Примеры таких выборок представлены в таблице 5. Строки таблицы описывают

отдельные сценарии фильтрации и не образуют полного разбиения корпуса. При фиксированном условии Harm $< 0{,}3$ повышение порога Edu с 0,5 до 0,7 примерно вдвое сокращает объем отбираемых данных.

Таблица 5: Примеры отбора документов по двум модельным характеристикам

Условие	Документов
Образовательная ценность > 0,7, риск < 0,3	4,038,903
Образовательная ценность > 0,5, риск < 0,3	8,023,315
Образовательная ценность < 0,3, риск < 0,3	20,532,230
Образовательная ценность < 0,3, риск > 0,7	985,261

Полученные результаты демонстрируют, что тематической принадлежности и одного общего показателя качества недостаточно для формирования обучающего корпуса. Большинство документов имеет низкий риск вредоносного содержания, но при этом также низкую образовательную ценность. Напротив, подмножество документов, одновременно имеющих высокую образовательную ценность и низкую оценку риска, составляет только около одной девятой исходной коллекции.

5. Анализ влияния образовательной ценности на качество LLM

5.1. Понятие образовательной ценности у современных LLM

Оценка образовательной ценности является менее однозначной характеристикой документа, чем, например, определение языка или тематической принадлежности. Даже при использовании одинаковой порядковой шкалы различные языковые модели могут поразному интерпретировать границы между ее значениями. Поэтому дополнительно было исследовано, насколько согласованно современные LLM понимают образовательную ценность и насколько получаемая числовая оценка зависит от выбора модели-аннотатора.

На первом этапе модели `DeepSeek-v4-Flash`, `Gemini-3.7-Flash` и `GPT-5.6-Luna` независимо получали запрос сформулировать собственное определение образовательной ценности веб-документа и предложить шкалу от 0 до 5. При этом моделям заранее не сообщалось определение, использовавшееся в нашей исходной разметке.

В ответах моделей наблюдался общий набор признаков образовательного текста. К ним относились наличие содержательных объяснений, причинно-следственных связей, логическая структура материала, контекст и возможность сформировать связное понимание темы. Наиболее заметное сходство наблюдалось в интерпретации максимального значения шкалы. Все рассмотренные модели склонны были резервировать оценку 5 для исключительно сильного образовательного материала. В предлагаемых ими шкалах такая оценка соответствовала образцовому учебному тексту, сочетающему глубину, систематичность, объяснение механизмов, работу с типичными ошибками и возможность переноса знаний.

На основании общих признаков была сформирована единая инструкция, использованная далее для всех сравниваемых моделей. В ней образовательная ценность определялась как полезность текста для обучения, расширения кругозора, получения содержательных или систематических знаний, понимания темы либо освоения практического навыка. Дополнительно было явно указано, что оценка 5 не требует идеального или исчерпываю-

щего учебного материала и может быть присвоена качественному фрагменту учебного, научно-познавательного или экспертного текста.

Для количественного сравнения была сформирована стратифицированная выборка из 1200 документов. Исходной стратификацией служили оценки, ранее полученные моделью `Qwen3-235B-A22B-Instruct` с более короткой версией инструкции. Для каждого значения исходной шкалы от 0 до 5 случайным образом выбиралось по 200 документов.

Одни и те же документы с одной и той же новой инструкцией были независимо размечены четырьмя моделями - DeepSeek, Gemini, GPT и Qwen. Модели возвращали целочисленную оценку от 0 до 5 и краткое текстовое обоснование. Исходные оценки Qwen, полученные с более короткой инструкцией, использовались как точка сравнения и как источник меток для обучения образовательного классификатора.

Поскольку шкала является порядковой, для анализа использовалось несколько типов метрик: доля точных совпадений, доля расхождений не более чем на один пункт, средняя абсолютная ошибка (MAE) и корреляция Спирмена.

В таблице 6 приведено согласие новых оценок с исходной разметкой.

Таблица 6: Согласованность новых оценок с исходной разметкой Qwen

Модель	Exact, %	± 1, %	MAE	Spearman ρ
DeepSeek-v4-Flash	25.2	56.4	1.392	0.738
Gemini-3.7-Flash	27.4	66.1	1.190	0.773
GPT-5.6-Luna	27.3	73.6	1.045	0.757
Qwen3-235B-A22B-Instruct	38.5	85.9	0.787	0.782

Повторная разметка той же моделью Qwen, но с новой инструкцией, показала наибольшее согласие с исходными оценками. Тем не менее точное совпадение наблюдалось только для 38.5% документов. В то же время в 85.9% случаев расхождение не превышало одного пункта, а коэффициент Спирмена составил 0.782. Это показывает, что даже для одной и той же модели числовая оценка существенно зависит от используемого определения и границ шкалы, несмотря на сохранение общего порядка документов по образовательной ценности.

Для остальных моделей также наблюдается достаточно высокая ранговая согласованность с исходной разметкой: коэффициент Спирмена находится в диапазоне от 0.738 до 0.773. При этом точное совпадение составляет только около четверти примеров. Такое сочетание результатов указывает на то, что модели в значительной степени сохраняют относительный порядок документов, но по-разному выбирают абсолютное значение на шкале от 0 до 5.

Особенно заметно различие при рассмотрении распределений предсказанных оценок. Средняя оценка DeepSeek составила 1.19, 1.45 для Gemini, 1.85 для GPT, и 2.31 для Qwen. При этом DeepSeek не присвоил оценку 5 ни одному из 1200 документов, тогда как Gemini присвоил ее 15 документам, GPT - 6, а Qwen - 65.

Дополнительно были рассчитаны метрики согласованности непосредственно между новыми разметками моделей, результаты приведены в таблице 7. Попарная ранговая корреляция между новыми разметками во всех случаях оказалась высокой: значения Spearman ρ лежат в диапазоне от 0.788 до 0.847. При этом доля точных совпадений изменяется значительно сильнее - от 19.8% для пары DeepSeek--Qwen до 66.6% для пары DeepSeek--Gemini.

На общей выборке из 1200 документов, для которых были получены ответы всех четырех моделей, полностью одинаковую оценку все модели присвоили только в 12.9% случа-

Таблица 7: Попарная согласованность моделей при использовании общей инструкции

Пара моделей	Exact, %	± 1, %	MAE	Spearman ρ
DeepSeek -- Qwen	19.8	73.0	1.128	0.803
DeepSeek -- GPT	37.8	93.6	0.693	0.788
DeepSeek -- Gemini	66.6	98.4	0.351	0.847
Qwen -- GPT	48.5	93.1	0.585	0.845
Qwen -- Gemini	30.3	84.6	0.872	0.847
GPT -- Gemini	55.0	98.4	0.466	0.837

ев. Однако для 69.5% документов разница между максимальной и минимальной оценкой среди четырех моделей составляла не более одного пункта, а для 94.2% - не более двух. Таким образом, большая часть расхождений носит порядковый характер и связана с выбором соседних областей шкалы.

Полученные результаты позволяют выделить два источника вариативности оценки образовательной ценности. Первый связан с формулировкой самого критерия: изменение инструкции приводит к заметному изменению абсолютных оценок даже при использовании одной и той же модели. Второй связан с моделью-аннотатором: при общей инструкции различные LLM систематически используют разные участки шкалы и имеют различную склонность к присвоению высоких значений. При этом модели схожим образом ранжируют документы, но выставляют им разные абсолютные оценки.

Числовой порог образовательной ценности нельзя напрямую переносить между моделями-аннотаторами. Для использования абсолютных порогов требуется отдельная калибровка модели или привязка к фиксированной размеченной выборке. В задачах сравнительного анализа документов более устойчивыми могут быть порядковые характеристики и относительное ранжирование, тогда как абсолютное значение оценки сильнее зависит от выбранной модели и инструкции.

5.2. Влияние образовательной ценности на эффективность обучения

Для проверки влияния образовательного отбора на обучение языковых моделей сравнивались два варианта обучающих данных, сформированных из исследуемой коллекции объемом 35,6 млн документов. Вариант *Edu* содержал документы с нормированной оценкой образовательной ценности выше 0,5. Контрольный вариант *Random* формировался случайным отбором документов из той же коллекции без ограничения на образовательную оценку. Для снижения влияния дисперсии содержания коллекций формируемых вариантом Random (в Edu выборка не зависит от запуска), расчет метрик для него выполнялся путем выбора лучших результатов среди 10 сформированных коллекций.

Использовалась архитектура Qwen3 в конфигурациях с приблизительно 100, 300 и 500 млн параметров. Для каждой размерности выполнялось обучение с нуля на Edu и Random; каждая обучающая коллекция содержала около 11 млрд токенов, обучение проводилось в течение одной эпохи. Длина контекста составляла 4096 токенов, а learning rate 10^{-3}. Такой объем был выбран в качестве фиксированного экспериментального бюджета для сравнения стратегий отбора данных. Аналогичный подход к предварительному исследованию состава обучающих данных применяется в OLMo 3 [10]: для подбора смесей используются модели с 30 млн параметров, обучаемые на 3 млрд токенов, с последующей оценкой полученных решений на более крупных моделях. Во всех конфигурациях использовался один и тот же BPE-токенизатор со словарем объемом 32 тыс. токенов.

Сравнение ограничено тремя размерами моделей и выбранным объемом данных. Эксперимент проверяет отбор по образовательной ценности; вклад тематической кластеризации и отбора предметных коллекций в качество предобучения отдельно не измерялся.

5.3. Метрика оценки

Модели оценивались на 15 наборах данных из состава LLMTF [11]. С учетом небольшого размера моделей и ограниченного объема предобучения для сравнения использовалась логарифмическая вероятность эталонного ответа. Такой подход позволяет измерять изменения вероятности правильного продолжения без требования к модели самостоятельно сгенерировать ответ или выбрать правильный вариант.

В используемой реализации LLMTF режим оценки PPL возвращает среднюю логарифмическую вероятность токенов эталонного ответа. Для набора данных j эта величина определяется как

$$\ell_j(\theta) = \frac{1}{n_j} \sum_{i=1}^{n_j} \frac{1}{T_{ji}} \sum_{t=1}^{T_{ji}} \log p_\theta(y_{ji,t} \mid c_{ji}, y_{ji,<t}) \,, \tag{11}$$

где θ - параметры модели, n_j - число примеров, c_{ji} - контекст задания, y_{ji} - эталонный ответ, а T_{ji} - число его токенов. Сначала усредняются логарифмические вероятности токенов каждого ответа, затем - значения для отдельных примеров. Используется натуральный логарифм.

Значения ℓ_j неположительны; большее значение соответствует большей вероятности эталонного ответа и лучшему результату. Они связаны с перплексией при том же усреднении соотношением $\mathrm{PPL}_j = \exp(-\ell_j)$. При таком усреднении PPL_j соответствует геометрическому среднему перплексий отдельных ответов. Итоговая оценка вычисляется как арифметическое среднее с одинаковым весом каждого набора данных:

$$\overline{\ell}(\theta) = \frac{1}{15} \sum_{j=1}^{15} \ell_j(\theta). \tag{12}$$

5.4. Результаты сравнения

Результаты представлены в таблице 8. Стрелка ↓ указывает направление улучшения, полужирным выделен лучший результат в каждой паре Edu/Random одинакового размера.

Для модели с 100 млн параметров образовательный отбор снижает отрицательную среднюю логарифмическую вероятность с $2{,}183$ до $2{,}134$, то есть приблизительно на $0{,}049$. Edu превосходит Random на 11 из 15 наборов данных. Наиболее заметные улучшения наблюдаются на ruMMLU ($+0{,}212$), enMMLU ($+0{,}157$), переводе с русского на английский ($+0{,}134$) и юридическом наборе Shlepa ($+0{,}126$). При этом результат Random лучше на collection3, копировании английского текста, книжном и музыкальном наборах Shlepa.

Для модели с 300 млн параметров средняя оценка снижается с $2{,}213$ для Random до $2{,}032$ для Edu. Выигрыш составляет $0{,}181$; Edu превосходит Random на 12 из 15 наборов данных. Наиболее заметные улучшения наблюдаются на наборах Shlepa по кино ($+0{,}631$) и книгам ($+0{,}412$), а также на ruMMLU ($+0{,}335$), enMMLU ($+0{,}325$) и музыкальном наборе Shlepa ($+0{,}320$). При этом Random дает меньшую ошибку на копировании английского и русского текста и на RuCoLA. Следовательно, образовательный отбор улучшает большинство рассматриваемых оценок, по-разному влияет на отдельные задачи.

Таблица 8: Отрицательная средняя логарифмическая вероятность эталонных ответов на наборах LLMTF после обучения на Edu и Random

Набор данных	100 млн		300 млн		500 млн	
	Edu ↓	Random ↓	Edu ↓	Random ↓	Edu ↓	Random ↓
RCC-MSU/collection3-(in-place)	1.191	**1.168**	**0.993**	1.030	1.052	**0.992**
ai-forever/kinopoisk	**1.467**	1.508	**1.440**	1.725	2.088	**1.644**
daru/treewayabstractive	**2.449**	2.478	**2.228**	2.247	**2.193**	2.220
darumeru/cp_para_en	0.127	**0.125**	0.113	**0.097**	0.102	**0.087**
darumeru/cp_para_ru	**0.068**	0.084	0.060	**0.050**	0.059	**0.054**
darumeru/flores_en_ru	**3.250**	3.362	**2.459**	2.552	**2.422**	2.528
darumeru/flores_ru_en	**3.770**	3.904	**2.959**	3.112	**2.844**	3.022
ilyagusev/gazeta	**2.148**	2.162	**1.912**	1.964	1.940	**1.910**
nlpcoreteam/enMMLU_few_shot	**1.966**	2.123	**1.964**	2.289	**1.995**	2.216
nlpcoreteam/ruMMLU_few_shot	**1.934**	2.146	**2.036**	2.371	2.058	**1.995**
russiannlp/rucola_custom	**0.683**	0.703	0.699	**0.677**	0.862	**0.763**
shlepa/books_mc	3.212	**3.112**	**3.072**	3.484	**2.990**	3.120
shlepa/law_mc	**3.249**	3.375	**3.923**	4.024	3.306	**3.262**
shlepa/movie_mc	**3.291**	3.357	**3.320**	3.951	3.158	**3.082**
shlepa/music_mc	3.203	**3.143**	**3.299**	3.619	**3.038**	3.281
Mean	**2.134**	2.183	**2.032**	2.213	**2.007**	2.012

Полужирным выделено наименьшее значение отдельно для каждой размерности модели. Для Random представлены лучшие результаты из десяти случайных подвыборок.

Для модели с 500 млн параметров средние оценки близки: 2,007 для Edu и 2,012 для Random. Преимущество Edu составляет около 0,005 по средней оценке и наблюдается на 6 из 15 наборов данных. Положительные изменения на музыкальном наборе Shlepa (+0,243), enMMLU (+0,221) и переводе с русского на английский (+0,178) сочетаются с ухудшением результатов на других задачах. Наиболее выраженное ухудшение наблюдается на kinopoisk: значение возрастает с 1,644 для Random до 2,088 для Edu. Таким образом, близость средних результатов не означает одинакового поведения моделей на отдельных наборах.

В рассмотренных конфигурациях наибольший средний выигрыш от образовательного отбора наблюдается для модели с 300 млн параметров (0,181), меньший - для модели с 100 млн параметров (0,049). Для модели с 500 млн параметров средний выигрыш составляет лишь 0,005. Таким образом, величина наблюдаемого эффекта не меняется монотонно с числом параметров модели, а на отдельных задачах сохраняются ухудшения. Эти наблюдения подтверждают возможность улучшения вероятностной оценки ответов за счет образовательного отбора, но не показывают универсального преимущества такого отбора для всех задач и размеров моделей.

6. Заключение

В работе предложена методология формирования доменно-ориентированных обучающих коллекций из крупномасштабных веб-корпусов. Подход основан на первичной тематической разметке с помощью LLM, семантической кластеризации свободных тегов, обучении компактного теггера и последующем масштабировании разметки на большую коллекцию документов. Помимо тематической принадлежности сохраняются независимые оценки характеристик документов, которые могут использоваться для последующего

отбора данных в зависимости от требований конкретной задачи.

Эксперименты на русскоязычной коллекции, сформированной на основе FineWeb2, показали значительную неоднородность веб-данных. Высокое языковое качество документа не гарантирует высокой образовательной ценности, а низкий риск потенциально вредного содержания не является достаточным условием полезности текста. Тематические разрезы также демонстрируют существенные различия характеристик между научными, образовательными, коммерческими и развлекательными категориями.

Отдельный эксперимент с несколькими современными LLM показал, что оценка образовательной ценности чувствительна как к формулировке критерия, так и к выбору модели-аннотатора. Несмотря на высокую ранговую согласованность оценок, модели существенно различаются в использовании абсолютной шкалы от 0 до 5. Следовательно, числовые пороги образовательной ценности не следует напрямую переносить между различными моделями без дополнительной калибровки.

При обучении с нуля на одинаковом объеме данных образовательный отбор повысил среднюю логарифмическую вероятность эталонных ответов LLMTF для моделей с 100 и 300 млн параметров и дал улучшение соответственно на 11 и 12 из 15 наборов. Наибольшее снижение средней отрицательной логарифмической вероятности наблюдалось для модели с 300 млн параметров и составило $0{,}181$. Для модели с 500 млн параметров средние результаты Edu и Random оказались близки, а изменения на отдельных задачах были разнонаправленными. Следовательно, эффективность образовательного фильтра следует оценивать с учетом размера модели и набора целевых задач.

Сохраненная разметка позволяет менять состав обучающей коллекции, задавая условия по тематике и качеству документов, без повторной обработки текстов.

Благодарности

Обучение и оценка языковых моделей выполнены на суперкомпьютере «МГУ-270» Московского государственного университета имени М. В. Ломоносова.

Список литературы

[1] L. Gao et al. *The Pile: An 800GB Dataset of Diverse Text for Language Modeling*. 2020. https://arxiv.org/abs/2101.00027

[2] J. Abadji et al. *Towards a Cleaner Document-Oriented Multilingual Crawled Corpus*. 2022. https://aclanthology.org/2022.lrec-1.463/

[3] G. Penedo et al. *The RefinedWeb Dataset for Falcon LLM: Outperforming Curated Corpora with Web Data, and Web Data Only*. 2023. https://arxiv.org/abs/2306.01116

[4] T. Nguyen et al. *CulturaX: A Cleaned, Enormous, and Multilingual Dataset for Large Language Models in 167 Languages*. 2024. https://aclanthology.org/2024.lrec-main.377/

[5] Penedo, Guilherme, et al. "The fineweb datasets: Decanting the web for the finest text data at scale." Advances in Neural Information Processing Systems 37 (2024): 30811-30849.

[6] Penedo, Guilherme, et al. "FineWeb2: One Pipeline to Scale Them All--Adapting Pre-Training Data Processing to Every Language." (2025).

[7] Д. Стоянов. *Модели T-lite и T-pro: training report*. Блог Т-Банка, 12 марта 2025 г. https://habr.com/ru/companies/tbank/articles/890236/

[8] GigaChat Team. *GigaChat Family: Efficient Russian Language Modeling Through Mixture of Experts Architecture*. 2025. arXiv:2506.09440. https://arxiv.org/abs/2506.09440

[9] A. Nikolich, K. Korolev, S. Bratchikov, I. Kiselev, A. Shelmanov. *Vikhr: The Family of Open-Source Instruction-Tuned Large Language Models for Russian*. 2024. arXiv:2405.13929. https://arxiv.org/abs/2405.13929

[10] Team Olmo. *Olmo 3*. 2025. arXiv:2512.13961. https://arxiv.org/abs/2512.13961

[11] M. Tikhomirov, E. Zlunikin, D. Grigoriev, D. Chernyshev. *LLMTF: An Open Framework and Benchmark for Evaluating Large Language Models in Russian*. Computational Linguistics and Intellectual Technologies: Proceedings of the International Conference Dialogue 2026. 2026, issue 24, pp. 627--643. DOI: 10.29003/2075-7182-2026-24-627-643.